دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

دانشکده ریاضی و علوم کامپیوتر

استاد درس: دکتر مهدی قطعی

استاد کارگاه: بهنام یوسفی مهر

مهر ۱۴۰۵

پیش‌بینی عوارض بعد از سکته قلبی

درس هوش مصنوعی و کارگاه

فهرست مطالب

۱ مقدمه ۵

۲ معرفی دیتاست ۵

۳ ویژگی‌ها ۶

۱.۳ پیش از خواندن ویژگی‌ها: چند مفهوم پایه ۷

۲.۳ نقشه کلی دسته‌های ویژگی ۸

۳.۳ انواع ستون‌ها و نحوه خواندن آن‌ها ۱۰

۴ متغیرهای هدف (Target Variables) ۱۱

۱.۴ متغیر هدف LET_IS ۱۲

۵ مقادیر گمشده ۱۳

۶ مرور مقالات ۱۴

۱.۶ Golovenkin et al., GigaScience 2020 . . . . . ۱۴

۲.۶ Yavru & Yılmaz Gündüz, ESTUJST 2022 . . . . . ۱۵

۳.۶ Ghafari et al., JTHC 2023 . . . . . ۱۵

۴.۶ Vicente et al., arXiv 2024 . . . . . ۱۶

۵.۶ Makhmudov et al., Bioengineering 2025 . . . . . ۱۶

۶.۶ Guo et al., Scientific Reports 2026 . . . . . ۱۷

۷ تعریف مسئله ۱۸

۱.۷ مسیر پیشنهادی انجام پروژه ۱۹

۸ ورودی و خروجی ۲۰

۹ تقسیم‌بندی داده ۲۰

۱۰ الزامات مدل‌سازی ۲۱

۱.۱۰ مدل‌های اجباری ۲۱

۲.۱۰ مدل نهایی ۲۲

۳.۱۰ قوانین خط لوله ۲۲

۱۱ کالیبراسیون ۲۳

۱.۱۱ کالیبراسیون چیست و چرا مهم است ۲۳

۲.۱۱ سنجش کالیبراسیون ۲۴

۳.۱۱ الگوریتم‌های کالیبراسیون ۲۴

۱۲ معیارهای ارزیابی ۲۶

۱.۱۲ مساحت زیر منحنی دقت‌ـبازیابی (AUPRC) ۲۶

۲.۱۲ مساحت زیر منحنی ROC (AUROC) ۲۷

۳.۱۲ Brier score و Brier Skill Score ۲۷

۴.۱۲ Log loss **(امتیازی)** ۲۷

۵.۱۲ معیارهای وابسته به آستانه ۲۸

۶.۱۲ تحلیل منحنی تصمیم (Decision Curve Analysis) **(امتیازی)** ۲۸

۷.۱۲ بازه اطمینان و مقایسه مدل‌ها ۲۹

۱۳ سوالات ۲۹

آ واژه‌نامه ستون‌های ورودی ۳۱

آ.۱ مشخصات جمعیتی و پیشینه بالینی (Demographic & Clinical History) ۳۱

آ.۲ سابقه آریتمی (Arrhythmia History) ۳۲

آ.۳ سابقه بلوک هدایتی (Conduction Block History) ۳۳

آ.۴ بیماری‌های همراه (Comorbidities) ۳۳

آ.۵ پارامترهای همودینامیک و وضعیت بدو پذیرش (Hemodynamic Parameters & Admission Status) ۳۴
آ.۶ یافته‌های نوار قلبی (Electrocardiographic Findings) ۳۵
آ.۷ درمان فیبرینولیتیک (Fibrinolytic Therapy) ۳۷
آ.۸ نتایج آزمایشگاهی (Laboratory Results) ۳۸
آ.۹ زمان‌بندی و تکرار درد (Timing & Pain Recurrence) ۳۸
آ.۱۰ داروهای پیش‌بیمارستانی (Pre-hospital Medications by Emergency Team) ۳۹
آ.۱۱ داروهای دوره بستری در ICU (In-hospital ICU Medications) ۳۹

ب متغیرهای هدف به زبان ساده ۴۰

ب.۱ یک تصویر ساده از قلب ۴۰
ب.۲ عوارض مربوط به بی‌نظمی ضربان (آریتمی‌ها) ۴۰
ب.۳ عوارض مربوط به ضعف پمپ ۴۱
ب.۴ عوارض ساختاری و التهابی ۴۱
ب.۵ عوارض مربوط به ادامه بیماری رگ‌ها ۴۲
ب.۶ پیامد نهایی: ★ LET_IS ۴۲

تحویل‌دادنی‌ها ۴۴

۱ مقدمه

سکته قلبی (انفارکتوس میوکارد) یکی از مهم‌ترین علل مرگ در جهان است. بخش بزرگی از مرگ‌ها و آسیب‌های پس از سکته، نه به خاطر خود سکته، بلکه به دلیل عوارضی رخ می‌دهد که در روزهای اول بستری ظاهر می‌شوند؛ عوارضی مثل آریتمی‌های خطرناک، ادم ریه یا پارگی دیواره قلب. اگر بتوان در همان لحظه پذیرش بیمار، خطر هر یک از این عوارض را تخمین زد، تیم درمان می‌تواند بیماران پرخطر را زودتر شناسایی کند، پایش ویژه‌تری برایشان در نظر بگیرد و اقدامات پیشگیرانه را به موقع انجام دهد.

در این پروژه شما با یک دیتاست واقعی بالینی کار می‌کنید و مدلی می‌سازید که برای هر بیمار احتمال مرگ و دو عارضه مهم پس از سکته را پیش‌بینی کند. این مسئله چند ویژگی دارد که آن را از یک تمرین ساده طبقه‌بندی جدا می‌کند: تعداد نمونه‌ها کم است، بسیاری از پیامدها نادرند، داده گمشده زیاد است و بخشی از ویژگی‌ها در زمان‌های مختلف بستری ثبت شده‌اند. به همین دلیل در این پروژه فقط رسیدن به یک عدد بالا مهم نیست؛ اعتبار ارزیابی، کیفیت احتمال‌ها و تفسیر نتایج هم به همان اندازه اهمیت دارند.

این سند به این ترتیب پیش می‌رود: ابتدا دیتاست، ویژگی‌ها و متغیرهای هدف آن را معرفی می‌کنیم. سپس مروری بر مقالاتی داریم که روی همین دیتاست کار کرده‌اند. بعد از آن مسئله پروژه را تعریف می‌کنیم و الزامات مدل‌سازی، روش ارزیابی، سوالات و تحویل‌دادنی‌ها را توضیح می‌دهیم. بخش‌هایی که با برچسب **(امتیازی)** مشخص شده‌اند اختیاری‌اند و نمره اضافه دارند.

> **فراتر از یک پروژه درسی.** این پروژه بر پایه دیتاستی واقعی و مسئله‌ای باز در پژوهش‌های بالینی تعریف شده است. دانشجویانی که تمام مراحل پروژه، از جمله بخش‌های امتیازی، را با دقت و اعتبار روش‌شناختی کامل انجام دهند و به نتایجی بهتر از نتایج گزارش‌شده در مقالات مرورشده دست یابند، می‌توانند ادامه و گسترش کار خود را در قالب یک پژوهش جدی در نظر بگیرند. چنین کاری، پس از بررسی‌های تکمیلی و با راهنمایی استاد درس، این ظرفیت را دارد که به یک مقاله علمی قابل انتشار تبدیل شود. در این صورت، دقت در ارزیابی منصفانه، مستندسازی کامل و قابلیت بازتولید نتایج اهمیتی دوچندان پیدا می‌کند.

حالا برویم سراغ دیتاستی که در این پروژه با آن کار خواهید کرد.

۲ معرفی دیتاست

دیتاست Myocardial Infarction (MI) Complications از مخزن UCI Machine Learning Repository برگرفته شده است و حاوی اطلاعات بالینی بیمارانی است که دچار سکته قلبی (Myocardial Infarction، مرگ بخشی از عضله قلب به دلیل قطع جریان خون) شده‌اند. این دیتاست در بیمارستان بالینی شماره ۲۰ بین‌منطقه‌ای کراسنویارسک (Krasnoyarsk Interdistrict Clinical Hospital No. 20) در روسیه، طی سال‌های ۱۹۹۲ تا ۱۹۹۵ جمع‌آوری شده و هدف آن فراهم کردن

مسئله‌ای واقعی و پیچیده برای مقایسه روش‌های داده‌کاوی و تشخیص الگو، یعنی پیش‌بینی عوارض (Complications) ناشی از سکته قلبی حاد (Acute Myocardial Infarction, AMI) است. حدود نیمی از بیماران در مراحل حاد و تحت‌حاد دچار عارضه می‌شوند و حتی پزشک مجرب نیز همیشه نمی‌تواند بروز آن را پیش‌بینی کند.

صفحه مستندات و دانلود دیتاست

- صفحه دیتاست در مخزن UCI (شناسه ۵۷۹):

https://archive.ics.uci.edu/dataset/579/myocardial+infarction+complications

جدول ۱.۲: مشخصات کلی دیتاست

ویژگی	مقدار
تعداد نمونه‌ها	۱۷۰۰
تعداد ویژگی‌های ورودی	۱۱۱
تعداد متغیرهای هدف	۱۲
نوع داده‌ها	عددی (پیوسته) و دسته‌ای (باینری و ترتیبی)
مقادیر گمشده	دارد
منبع	UCI ML Repository

هر رکورد نمایانگر یک بیمار است. اطلاعات هر بیمار در سه مرحله ثبت شده است: (۱) سابقه پزشکی (Anamnesis) پیش از بستری، (۲) زمان پذیرش و ارزیابی اولیه توسط تیم اورژانس قلب، و (۳) دوره بستری در بخش مراقبت‌های ویژه (ICU: Intensive Care Unit، بخش تخصصی پایش و درمان بیماران بدحال) که شامل اندازه‌گیری‌های روزهای اول تا سوم است. متغیرهای هدف پیامدهای بالینی‌اند که در پایان دوره بستری ثبت شده‌اند.

ستون‌های فایل داده به این صورت مرتب شده‌اند: ستون ۱ شناسه رکورد (ID) است و در مدل‌سازی استفاده نمی‌شود، ستون‌های ۲ تا ۱۱۲ ویژگی‌های ورودی، و ستون‌های ۱۱۳ تا ۱۲۴ متغیرهای هدف هستند.

۳ ویژگی‌ها

دیتاست شامل ۱۱۱ ویژگی ورودی (ستون‌های ۲ تا ۱۱۲) است. بیشتر این ویژگی‌ها اصطلاحات پزشکی‌اند و ممکن است در نگاه اول ناآشنا باشند. برای کار با آن‌ها لازم نیست پزشک باشید؛ کافی است چند مفهوم پایه را بدانید و بفهمید هر ویژگی **چه زمانی**

ثبت شده و **چه چیزی** درباره وضعیت بیمار می‌گوید. این بخش با همین مفاهیم پایه شروع می‌شود و بعد نقشه کلی دسته‌های ویژگی و انواع ستون‌ها را توضیح می‌دهد.

آنچه درباره ویژگی‌ها از شما انتظار داریم. این یک پروژه یادگیری ماشین است، نه پزشکی. از شما انتظار **نداریم** معنای پزشکی تک‌تک ۱۱۱ ستون را بدانید یا آن‌ها را از نظر بالینی تحلیل کنید. برای انجام پروژه فقط این سه چیز لازم است:

۱. **نوع هر ستون** (دودویی، ترتیبی یا پیوسته) تا بدانید چطور پیش‌پردازشش کنید (بخش ۳.۳).

۲. **زمان ثبت هر ستون** تا ستون‌های ممنوع را حذف کنید (جدول ۳.۳).

۳. **نرخ گمشدگی هر ستون** که خودتان از داده محاسبه می‌کنید.

بقیه این بخش برای این است که داده برایتان ملموس شود و بتوانید نتایج مدل را بهتر بخوانید. توضیح ستون‌به‌ستون در **پیوست آ** آمده است؛ هر وقت به اسم ستونی برخوردید که معنایش را نمی‌دانستید، آنجا جستجو کنید.

۱.۳ پیش از خواندن ویژگی‌ها: چند مفهوم پایه

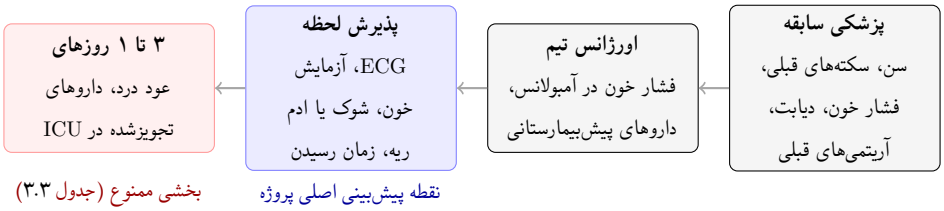
قلب و سیستم الکتریکی آن. قلب چهار حفره دارد: دو **دهلیز** (atrium) در بالا که خون را دریافت می‌کنند و دو **بطن** (ventricle) در پایین که خون را به بدن پمپ می‌کنند. هر ضربان با یک سیگنال الکتریکی شروع می‌شود: سیگنال از **گره سینوسی** (ضربان‌ساز طبیعی قلب، در دهلیز راست) شروع می‌شود، از دهلیزها عبور می‌کند، به **گره AV** (دروازه بین دهلیز و بطن) می‌رسد و از طریق **شاخه‌های چپ و راست** در بطن‌ها پخش می‌شود. تقریباً همه ویژگی‌های قلبی این دیتاست درباره یکی از این سه چیز هستند:

- **آسیب عضله قلب (سکته):** اگر رگی که به بخشی از قلب خون می‌رساند بسته شود، آن بخش از عضله آسیب می‌بیند. محل و وسعت این آسیب مهم است؛ هرچه آسیب بزرگ‌تر باشد، پمپاژ ضعیف‌تر و خطر نارسایی قلب و مرگ بیشتر است.
- **آریتمی (اختلال ریتم):** ضربان بیش از حد تند (**تاکی‌کاردی**)، بیش از حد کند (**برادی‌کاردی**)، یا آشفته و نامنظم (**فیبریلاسیون**). اگر منشأ مشکل در دهلیز باشد معمولاً کم‌خطرتر است و اگر در بطن باشد (مثل فیبریلاسیون بطنی) می‌تواند در چند دقیقه کشنده باشد.
- **بلوک هدایتی:** سیگنال الکتریکی در مسیر کند می‌شود یا قطع می‌شود. «درجه» بلوک شدت آن را نشان می‌دهد؛ در بلوک درجه سه ارتباط دهلیز و بطن کاملاً قطع است.

نوار قلب (ECG). ابزاری است که همین فعالیت الکتریکی را ثبت می‌کند. پس ویژگی‌های ECG همان سه موضوع بالا (محل

آسیب، آریتمی و بلوک) را در لحظه پذیرش نشان می‌دهند، در حالی که ویژگی‌های «سابقه» همان موضوع‌ها را در گذشته بیمار نشان می‌دهند.

مسیر بیمار در زمان. ویژگی‌ها در زمان‌های مختلف ثبت شده‌اند و این برای مسئله ما مهم است، چون مدل فقط می‌تواند از اطلاعاتی استفاده کند که تا لحظه پیش‌بینی وجود داشته است. شکل ۱.۳ این مسیر را نشان می‌دهد.



شکل ۱.۳: زمان ثبت ویژگی‌ها در مسیر بیمار. پیامدها (عوارض و مرگ) بعد از همه این مراحل رخ می‌دهند.

۲.۳ نقشه کلی دسته‌های ویژگی

ویژگی‌ها در یازده دسته بالینی قرار می‌گیرند. جدول ۱.۳ برای هر دسته به زبان ساده می‌گوید چه اطلاعاتی می‌دهد و چرا ممکن است برای پیش‌بینی عوارض مفید باشد. ستون آخر فقط فرضیه بالینی است؛ اینکه داده واقعاً آن را تأیید می‌کند یا نه، چیزی است که شما باید در تحلیل‌تان بررسی کنید.

جدول ۱.۳: دسته‌های ویژگی، معنای ساده آن‌ها و ارتباط احتمالی با پیامدها

دسته	به زبان ساده	زمان ثبت	چرا ممکن است مهم باشد
مشخصات جمعیتی و پیشینه بالینی	سن، جنس، سکته‌های قبلی، آنژین و فشار خون در گذشته	پیش از بستری	قلب مسن‌تر یا قلبی که قبلاً آسیب دیده ذخیره کمتری دارد و نارسایی و مرگ در آن محتمل‌تر است
سابقه آریتمی	آیا بیمار قبلاً اختلال ریتم داشته است	پیش از بستری	قلبی که قبلاً آریتمی داشته، مستعد تکرار آن (مثلاً فیبریلاسیون دهلیزی) است
سابقه بلوک هدایتی	آیا سیم‌کشی الکتریکی قلب قبلاً مشکل داشته است	پیش از بستری	مسیر هدایت آسیب‌دیده با سکته جدید ممکن است کاملاً قطع شود (بلوک AV)
بیماری‌های همراه	دیابت، چاقی، تیروئید و بیماری‌های ریوی	پیش از بستری	بهبود را سخت‌تر می‌کنند؛ پرکاری تیروئید ضربان را تند می‌کند
فشار خون و وضعیت بدو پذیرش	فشار خون، شوک، ادم ریه و آریتمی در لحظه رسیدن	اورژانس و پذیرش	نشانه مستقیم شدت وضعیت؛ فشار پایین و شوک از قوی‌ترین نشانه‌های خطر مرگ‌اند
نوار قلبی (ECG)	محل سکته، ریتم، آریتمی و بلوک در لحظه پذیرش	پذیرش	سکته دیواره قدامی معمولاً وسیع‌تر است (خطر نارسایی)؛ سکته دیواره تحتانی با بلوک AV مرتبط است
درمان فیبرینولیتیک	آیا داروی حل‌کننده لخته داده شده و با چه دوزی	پذیرش	باز شدن رگ می‌تواند وسعت آسیب را کم کند
نتایج آزمایشگاهی	پتاسیم، سدیم، آنزیم‌های قلبی و کبدی، گلبول سفید	پذیرش	به هم خوردن پتاسیم و سدیم آریتمی می‌آورد؛ آنزیم‌های بالا یعنی آسیب بزرگ‌تر
زمان‌بندی و عود درد	فاصله شروع حمله تا بیمارستان؛ تکرار درد در روزهای بستری	پذیرش تا روز سوم (جدول ۳.۳)	دیر رسیدن یعنی آسیب بیشتر؛ عود درد یعنی ادامه کم‌خونی عضله قلب
داروهای تیم اورژانس	داروهایی که پیش از بیمارستان داده شده	پیش‌بیمارستانی	شدت وضعیتی را نشان می‌دهد که تیم اورژانس دیده است
داروهای دوره بستری در ICU	داروهایی که پزشکان در بخش ویژه تجویز کرده‌اند	روز اول تا سوم (جدول ۳.۳)	بیشتر قضاوت پزشک درباره خطر بیمار را نشان می‌دهند تا اثر خود دارو را

درمان، علت نیست. اگر مدل شما نشان داد بیمارانی که داروی خاصی گرفته‌اند بیشتر دچار عارضه شده‌اند، معمولاً به این معناست که پزشک آن دارو را برای بیماران بدحال‌تر تجویز کرده است، نه اینکه دارو باعث عارضه شده باشد. هنگام تفسیر اهمیت ویژگی‌ها این نکته را در نظر داشته باشید (سوال مربوط به هپارین در بخش سوالات).

۳.۳ انواع ستون‌ها و نحوه خواندن آن‌ها

ستون‌های این دیتاست سه نوع اصلی دارند و نوع هر ستون روی پیش‌پردازش اثر می‌گذارد:

جدول ۲.۳: انواع ستون‌ها در دیتاست

نوع	مثال	نکته
دودویی (۰/۱)	SEX، SIM_GIPERT، nr01، K_SH_POST	بیشترین تعداد ستون‌ها؛ ۱ یعنی «دارد یا رخ داده» و ۰ یعنی «ندارد»
ترتیبی	GB (مرحله ۰ تا ۳)، FK_STENOK (کلاس ۰ تا ۴)، TIME_B_S (۱ تا ۹)، ZSN_A	اعداد ترتیب دارند ولی فاصله‌ها لزوماً برابر نیست؛ معنای هر کد را از پیوست آ یا سند رسمی بخوانید
پیوسته	AGE، فشار خون‌ها، K_BLOOD، Na_BLOOD، KFK_BLOOD، L_BLOOD	واحد هر ستون در توضیحات آمده است؛ مقادیر غیرعادی را با محدوده طبیعی مقایسه کنید

پیشنهاد برای شروع: قبل از مدل‌سازی، توزیع چند ویژگی از هر دسته را رسم کنید و فراوانی هر پیامد را در گروه‌های مختلف آن ویژگی مقایسه کنید (مثلاً نرخ مرگ در بیماران با و بدون شوک هنگام پذیرش). این کار هم معنای ویژگی‌ها را برایتان ملموس می‌کند و هم خطاهای داده را زود نشان می‌دهد. برای جزئیات کامل هر ستون، سند توضیحات رسمی را ببینید.

دستورالعمل عملی: اگر نمی‌دانید با ستون‌ها چه کنید، این روش ساده کافی است و نیاز به دانش پزشکی ندارد:

- ستون ID، ستون‌های ممنوع جدول ۳.۳ و ۱۲ ستون پیامد را از ورودی حذف کنید.
- ستون‌هایی که درصد بسیار بالایی مقدار گمشده دارند (مثلاً بیش از ٪۵۰، بر اساس داده آموزش) را می‌توانید حذف کنید.
- ستون‌های دودویی و ترتیبی را همان‌طور که هستند (به صورت عدد) نگه دارید. نیازی به one-hot نیست.
- ستون‌های پیوسته را برای رگرسیون لجستیک استاندارد کنید (StandardScaler)؛ مدل‌های درختی به این کار نیاز ندارند.

- مقادیر گمشده را داخل Pipeline جایگذاری کنید: میانه برای ستون‌های پیوسته و مُد برای بقیه. LightGBM و XGBoost خودشان با مقدار گمشده کار می‌کنند.

لحظه‌های پیش‌بینی و ستون‌های مجاز

سند توضیحات دیتاست چهار لحظه برای پیش‌بینی تعریف می‌کند. در هر لحظه فقط ستون‌هایی می‌توانند ورودی مدل باشند که تا آن زمان در دسترس بوده‌اند. استفاده از ستون‌های ثبت‌شده بعدی در آن لحظه، نشت اطلاعات (Data Leakage) است. شماره‌ها ستون‌های فایل هستند و ستون ID را هم شامل می‌شوند.

جدول ۳.۳: لحظه‌های پیش‌بینی و ستون‌های حذف‌شده از ورودی

لحظه پیش‌بینی	ستون‌های ممنوع	نام ستون‌های ممنوع
زمان پذیرش	93–95, 100–105	R_AB_1_n تا R_AB_3_n، NA_R_1_n تا NA_R_3_n، NOT_NA_1_n تا NOT_NA_3_n
پایان روز اول (۲۴ ساعت)	94, 95, 101, 102, 104, 105	مقادیر روز دوم و سوم همان ستون‌ها
پایان روز دوم (۴۸ ساعت)	95, 102, 105	مقادیر روز سوم
پایان روز سوم (۷۲ ساعت)	—	همه ستون‌های 2–112 مجازند

توجه کنید که سایر داروهای دوره بستری (ستون‌های ۱۰۶ تا ۱۱۲) طبق سند رسمی دیتاست در همه لحظه‌ها مجاز شمرده شده‌اند. در این پروژه همین تعریف را مبنا قرار دهید.

۴ متغیرهای هدف (Target Variables)

دیتاست دارای ۱۲ متغیر هدف است که هر یک نمایانگر یک عارضه یا پیامد بالینی احتمالی در دوره بستری بیمار مبتلا به MI است. تمامی متغیرها به جز LET_IS از نوع باینری هستند؛ مقدار 1 به معنای بروز عارضه و مقدار 0 به معنای عدم بروز آن است.

اسم این عارضه‌ها برایتان ناآشناست؟ نگران نباشید؛ برای انجام پروژه لازم نیست پزشکی بدانید. توضیح هر متغیر هدف به زبان ساده، اینکه چه اتفاقی در بدن بیمار می‌افتد و چرا خطرناک است، در **پیوست ب** آمده است. اگر می‌خواهید با مفهوم این پیامدها آشنا شوید، به آنجا مراجعه کنید.

جدول ۱.۴: متغیرهای هدف دیتاست MI Complications

ردیف	نام متغیر	نوع	توضیح بالینی
۱	FIBR_PREDS	باینری	فیبریلاسیون دهلیزی (Atrial Fibrillation)
۲	PREDS_TAH	باینری	تاکی‌کاردی فوق‌بطنی (Supraventricular Tachycardia)
۳	JELUD_TAH	باینری	تاکی‌کاردی بطنی (Ventricular Tachycardia)
۴	FIBR_JELUD	باینری	فیبریلاسیون بطنی (Ventricular Fibrillation)
۵	A_V_BLOK	باینری	بلوک AV درجه سوم (Third-degree AV Block)
۶	OTEK_LANC	باینری	ادم ریوی (Pulmonary Edema)
۷	RAZRIV	باینری	پارگی میوکارد (Myocardial Rupture)
۸	DRESSLER	باینری	سندرم درسلر (Dressler Syndrome)
۹	ZSN	باینری	نارسایی مزمن قلبی (Chronic Heart Failure)
۱۰	REC_IM	باینری	عود سکته قلبی (Relapse of MI)
۱۱	P_IM_STEN	باینری	آنژین پس از انفارکتوس (Post-infarction Angina)
۱۲	LET_IS	چندکلاسه	پیامد نهایی بستری (Lethal Outcome)؛ جزئیات در جدول ۲.۴

۱.۴ متغیر هدف LET_IS

متغیر LET_IS برخلاف سایر متغیرهای هدف یک متغیر چندکلاسه (Multiclass) است که پیامد نهایی بیمار در طول بستری را مشخص می‌کند. مقادیر 1 تا 7 هر یک بیانگر یک علت مشخص مرگ در بیمارستان هستند و مقدار 0 در مستند رسمی دیتاست به عنوان نتیجه نامشخص (Unknown) ثبت شده است.

جدول ۲.۴: مقادیر متغیر هدف LET_IS

مقدار	توضیح
0	نتیجه نامشخص یا بدون پیامد کشنده (Unknown / No Lethal Outcome)
1	مرگ ناشی از شوک کاردیوژنیک (Cardiogenic Shock)
2	مرگ ناشی از ادم ریوی (Pulmonary Edema)
3	مرگ ناشی از پارگی میوکارد (Myocardial Rupture)
4	مرگ ناشی از نارسایی پیشرونده قلبی (Progressive Heart Failure)
5	مرگ ناشی از ترومبوآمبولی (Thromboembolism، انسداد رگ توسط لخته خون)
6	مرگ ناشی از آسیستول (Asystole، توقف کامل فعالیت الکتریکی قلب)
7	مرگ ناشی از فیبریلاسیون بطنی (Ventricular Fibrillation)

در مسائل یادگیری ماشین، LET_IS را می‌توان به دو شکل مورد استفاده قرار داد:

- **طبقه‌بندی چندکلاسه:** پیش‌بینی دقیق علت مرگ (مقادیر 0 تا 7)
- **طبقه‌بندی باینری:** پیش‌بینی بقا در مقابل مرگ (مقدار 0 در برابر مقادیر 1 تا 7)

در این پروژه از حالت باینری استفاده می‌کنیم: مقدار 0 را «زنده» و مقادیر 1 تا 7 را «فوت» در نظر بگیرید. با این تعریف ۲۷۱ بیمار (حدود ۱۶٪) فوت کرده‌اند.

برای مشاهده توضیحات بیشتر دیتاست، **سند توضیحات رسمی (PDF)** را ببینید.

۵ مقادیر گمشده

نرخ مقادیر گمشده در این دیتاست بالاست: از حدود 188,700 سلول، حدود 8.47% داده گم شده است، و تعداد زیادی از ستون‌ها دست‌کم یک مقدار گمشده دارند. برخی ستون‌ها نرخ گمشدگی بسیار بالایی دارند و عملاً قابل استفاده نیستند. بنابراین مدیریت مقادیر گمشده بخش جدایی‌ناپذیر پیش‌پردازش است.

روش مدیریت مقادیر گمشده (حذف ستون، جای‌گذاری، افزودن شاخص گمشدگی یا استفاده از مدل‌هایی که خودشان با داده گمشده کار می‌کنند) را با توجه به نوع داده و نرخ گمشدگی هر ستون خودتان انتخاب کنید و در گزارش توضیح دهید. فقط توجه کنید که هر پارامتری که برای این کار یاد گرفته می‌شود (مثلاً میانگین یا میانه یک ستون) باید فقط از داده آموزش محاسبه شود تا نشت اطلاعات رخ ندهد (بخش ۹).

۶ مرور مقالات

تا اینجا با دیتاست، ویژگی‌ها و متغیرهای هدف آن آشنا شدید. در این بخش سراغ مروری بر مقالاتی می‌رویم که روی همین دیتاست کار کرده‌اند. این مقالات رویکردهای متفاوتی دارند؛ از یادگیری بدون ناظر و تحلیل مسیرهای بالینی تا مدل‌های درختی، شبکه‌های عصبی چندوظیفه‌ای و شبکه‌های گرافی. خواندن آن‌ها کمک می‌کند ببینید دیگران این مسئله را چطور تعریف و ارزیابی کرده‌اند و چه اشتباهاتی ممکن است پیش بیاید.

برای هر مقاله یک خلاصه کوتاه و دو سوال آمده است. **شما باید به انتخاب خودتان یکی از مقالات را انتخاب کنید و در گزارشتان به هر دو سوال آن مقاله پاسخ دهید.** پاسخ‌ها باید با استدلال روشن و در صورت امکان با آزمایش روی همین دیتاست همراه باشند.

۱.۶ Golovenkin et al., GigaScience 2020

Trajectories, bifurcations, and pseudo-time in large clinical datasets: applications to myocardial infarction and diabetes data

DOI: 10.1093/gigascience/giaa128

این مقاله دیتاست را معرفی می‌کند و آن را از منظر یادگیری بدون ناظر بررسی می‌کند. ابتدا ویژگی‌ها و رکوردهای پرگمشده حذف و مقادیر ناموجود با SVDComplete تخمین زده شده و داده‌ها استاندارد شده‌اند. سپس با PCA بُعد کاهش یافته و با Elastic Principal Graph یک Principal Tree روی داده برازش شده است؛ هر بیمار روی درخت تصویر می‌شود و فاصلهٔ او از ریشه به‌عنوان pseudotime تعریف می‌شود. نتیجه ۱۰ مسیر بالینی است. درخت حدود ۵۲٪ واریانس را توضیح می‌دهد و در شش مسیر از ده مسیر خطر برآوردشدهٔ مرگ بالاتر است. مقاله مدل پیش‌بینی ندارد و معیار طبقه‌بندی گزارش نمی‌کند.

سوالات:

۱. PCA چه کاری با داده می‌کند و چرا قبل از ساختن درخت از آن استفاده شد؟

۲. Principal Tree چیست و با خوشه‌بندی KMeans چه فرقی دارد؟

۲.۶ Yavru & Yılmaz Gündüz, ESTUJST 2022

Predicting Myocardial Infarction Complications and Outcomes with Deep Learning

DOI: 10.18038/estubtda.1056821

هدف پیش‌بینی هر یک از ۱۲ خروجی دیتاست (۱۱ عارضه و مرگ) از روی ۱۱۱ ویژگی ورودی است. پیش‌پردازش شامل جای‌گذاری میانگین برای مقادیر گمشده و StandardScaler است و انتخاب ویژگی انجام نشده است. برای هر خروجی یک شبکهٔ عصبی جدا (لایه‌های ۶۴ و ۳۲ و ۱۶ نورونی با dropout و skip connection) روی تقسیم ۶۰/۲۰/۲۰ آموزش داده شده است. روی داده‌ی اصلی میانگین accuracy برابر ٪۹۲/۰۹ و sensitivity برابر ٪۴/۰۹ گزارش شده است. پس از augmentation نمونه‌های مثبت، accuracy برابر ٪۷۷/۴۹، sensitivity برابر ٪۵۱/۵۲ و precision برابر ٪۱۷/۸۸ شده است.

سوالات:

۱. sensitivity و specificity هرکدام یعنی چه؟ با یک مثال از ۱۰۰ بیمار توضیح دهید.

۲. accuracy مدل «همیشه منفی» را برای ۱۲ خروجی از روی نرخ مثبت هرکدام حساب کنید و با ٪۹۲/۰۹ مقایسه کنید. نتیجه دربارهٔ «بهترین دقت روی این دیتاست» چه می‌گوید؟

۳.۶ Ghafari et al., JTHC 2023

Prediction of the Fatal Acute Complications of Myocardial Infarction via Machine Learning Algorithms

DOI: 10.18502/jthc.v18i4.14827

مسئله دودویی تعریف شده است: بیمار در ۷۲ ساعت اول به‌خاطر یکی از عوارض مرگ‌بار فوت می‌کند (۲۷۱ نفر) یا زنده می‌ماند (۱۴۲۸ نفر). پس از جای‌گذاری میانگین، وزن‌دهی کلاس‌ها (class weight) و انتخاب ۵۰ ویژگی با RFE، چهار مدل رگرسیون لجستیک، SVM، جنگل تصادفی و XGBoost با ۵-fold CV و هشت معیار مقایسه شده‌اند. بهترین مدل XGBoost است با sensitivity برابر ٪۹۴/۳۵، specificity برابر ٪۶۹/۲۳، AUC برابر ٪۷۸/۶۵ و F1 برابر ٪۹۵/۱۴. تفسیر مدل با ELI5 انجام شده و مهم‌ترین ویژگی شوک کاردیوژنیک است.

سوالات:

۱. RFE (حذف بازگشتی ویژگی) مرحله‌به‌مرحله چطور کار می‌کند؟

۲. F1 برابر ٪۹۵/۱۴ را از sensitivity برابر ٪۹۴/۳۵ و precision برابر ٪۹۵/۹۵ بسازید. مربوط به کدام کلاس است و recall کلاس «فوت» چند است؟

۴.۶ Vicente et al., arXiv 2024

Explainable LightGBM Approach for Predicting Myocardial Infarction Mortality

DOI: 10.48550/arXiv.2404.15029

پرسش اصلی این است که آیا مدل‌های درخت تقویتی (XGBoost، LightGBM و CatBoost) به پیش‌پردازش سنگین نیاز دارند. برای پیش‌بینی مرگ (۲۷۱ فوت و ۱۴۲۹ زنده) دو خط‌لوله مقایسه شده است: یکی با حذف ستون‌های پرگمشده، random undersampling، کدگذاری، جای‌گذاری و انتخاب ویژگی با chi2، و دیگری با داده‌ی خام. تنظیم با grid search و ۱۰-fold CV روی ٪۸۰ آموزش و ارزیابی نهایی روی ٪۲۰ آزمون انجام شده است. LightGBM روی داده‌ی خام F1 برابر ۰/۹۱۲ و accuracy برابر ۰/۹۱۸ گرفته و تفاوت آن با حالت پیش‌پردازش‌شده در paired t-test معنادار نبوده است. تفسیر با Tree SHAP انجام شده است.

سوالات:

۱. SHAP چه چیزی را نشان می‌دهد؟ به زبان ساده توضیح دهید.

۲. «تفاوت معنادار نبود» با «پیش‌پردازش لازم نیست» چه فرقی دارد؟ چرا paired t-test روی foldهای CV مشکل دارد؟

۵.۶ Makhmudov et al., Bioengineering 2025

A Multitask Deep Learning Model for Predicting Myocardial Infarction Complications

DOI: 10.3390/bioengineering12050520

مقاله یک شبکهٔ عصبی چندوظیفه‌ای (Multi-Task Learning) پیشنهاد می‌کند که با لایه‌های پنهان مشترک (۵۱۲ و ۲۵۶ و ۱۲۸ نورون با Batch Normalization، L2 و dropout) هم‌زمان دو خروجی دارد: ۱۱ عارضه به‌صورت multi-label و علت مرگ در ۸ کلاس به‌صورت multiclass. برای نامتعادلی از random oversampling استفاده شده و ٪۲۰ داده‌ی آموزش برای اعتبارسنجی کنار گذاشته شده است. accuracy حدود ٪۷۷ برای عوارض و ٪۸۶ برای علت مرگ گزارش شده است. طبق Permutation Importance مهم‌ترین ویژگی‌ها سن و فشار خون سیستولیک هستند.

سوالات:

۱. Multi-label و multiclass چه فرقی دارند و چرا عوارض یکی و علت مرگ دیگری است؟

۲. اگر oversampling قبل از جدا کردن اعتبارسنجی انجام شده باشد، early stopping چرا خوش‌بین می‌شود؟

۶.۶ Guo et al., Scientific Reports 2026

Predicting complications and mortality in myocardial infarction patients using a graph neural network model

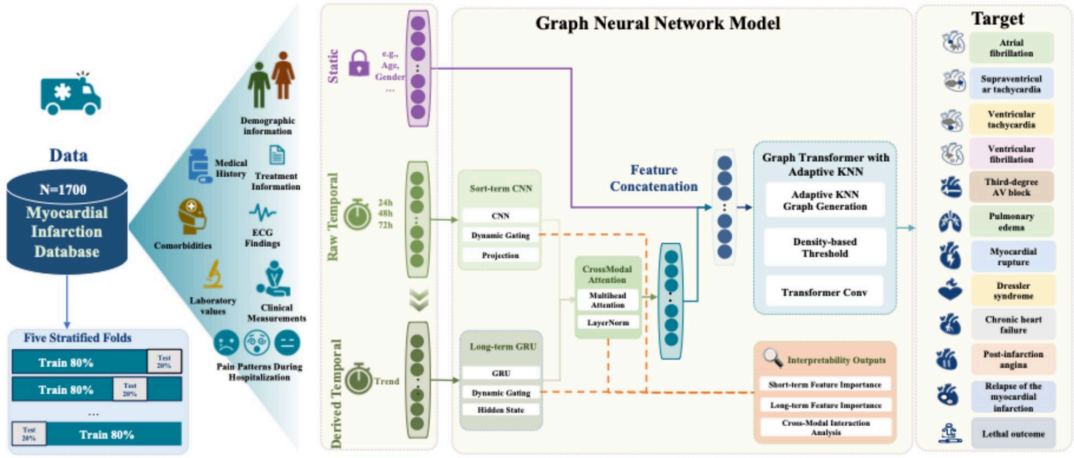
DOI: 10.1038/s41598-026-36798-3

این مقاله ۱۱ عارضه و مرگ را همزمان با یک شبکهٔ گرافی پیش‌بینی می‌کند. ورودی شامل ۱۰۲ ویژگی ثابت و ۹ متغیر پویای سه روز اول است. ابتدا گراف شباهت بیماران با KNN تطبیقی ساخته می‌شود. داده‌ی خام با CNN یک‌بعدی و روندها (اختلاف روزها، میانگین و شیب) با GRU کدگذاری می‌شوند، خروجی‌ها با توجه بین‌وجهی ادغام می‌شوند و به یک Graph Transformer با ۱۲ خروجی sigmoid می‌رسند. زیان Focal Loss با وزن کلاس مثبت است و ارزیابی با ۵-fold CV تکرارشده انجام شده است. میانگین AUC برابر ۰/۷۳۳ و F1 میانگین ۰/۲۶ است؛ برای مرگ AUC برابر ۰/۸۸۳ و F1 برابر ۰/۶۰۶ گزارش شده است.

سوالات:

۱. گراف بیماران یعنی چه؟ گره و یال هرکدام چیست؟

۲. با توجه به شکل، ویژگی‌های ثابت (سن، جنسیت و ...) مستقیم به مرحلهٔ Feature Concatenation می‌روند ولی داده‌ی زمانی از CNN و GRU عبور می‌کند. این طراحی چه مزیتی دارد؟ یک ablation طراحی کنید که سهم ویژگی‌های ثابت را در برابر ویژگی‌های زمانی بسنجد.



معماری مدل: گراف شباهت بیماران (KNN تطبیقی)، رمزگذار CNN برای داده‌ی خام کوتاه‌مدت و GRU برای روندها، ادغام با توجه بین‌وجهی، Graph Transformer و ۱۲ خروجی. منبع: Guo et al., Sci Rep 2026 (CC BY-NC-ND 4.0).

۷ تعریف مسئله

حالا که دیتاست را شناختید و دیدید پژوهش‌های قبلی با آن چه کرده‌اند، نوبت شماست. در این بخش مسئله پروژه را طرح می‌کنیم تا حل آن را شروع کنید. در بخش‌های بعدی هم ورودی و خروجی مدل، روش تقسیم داده، الزامات مدل‌سازی، کالیبراسیون و معیارهای ارزیابی را مشخص می‌کنیم.

مسئله: مدلی طراحی کنید که برای هر بیمار، با استفاده از اطلاعاتی که **در لحظه پذیرش در بیمارستان** در دسترس است، احتمال وقوع سه پیامد زیر را پیش‌بینی کند:

جدول ۱.۷: پیامدهای اصلی پروژه

پیامد	ستون	شیوع
مرگ (هر علتی)	LET_IS (باینری‌شده)	حدود ۱۶٪
نارسایی مزمن قلب	ZSN	حدود ۲۳٪
فیبریلاسیون دهلیزی	FIBR_PREDS	حدود ۱۰٪

این سه پیامد را انتخاب کرده‌ایم چون به اندازه کافی نمونه مثبت دارند تا بتوان مدل معتبری ساخت. برای هر پیامد یک مدل طبقه‌بندی دودویی جداگانه بسازید. پیش‌بینی ۹ عارضه دیگر، که بیشترشان بسیار نادرند، بخش امتیازی است.

هدف صرفاً رسیدن به دقت (accuracy) بالا نیست. مثلاً مدلی که برای همه بیماران «فوت نمی‌کند» پیش‌بینی کند، حدود ۸۴٪ دقت دارد و هیچ ارزشی ندارد. کار شما در چهار بُعد ارزیابی می‌شود:

۱. **شناسایی موارد مثبت:** مدل باید بیماران پرخطر را از بقیه جدا کند، حتی وقتی تعدادشان کم است.

۲. **اعتبار احتمال‌ها (کالیبراسیون):** اگر مدل برای گروهی از بیماران احتمال ۳۰٪ می‌دهد، باید حدود ۳۰٪ از آن‌ها واقعاً آن پیامد را تجربه کنند.

۳. **ارزیابی معتبر:** بدون نشت اطلاعات (data leakage) و با مقایسه منصفانه با مدل‌های پایه.

۴. **تفسیر:** مدل به چه ویژگی‌هایی تکیه می‌کند.

زمان پیش‌بینی: سناریوی پروژه «زمان پذیرش» است. طبق جدول ۳.۳، ستون‌های ۹۳ تا ۹۵ و ۱۰۰ تا ۱۰۵ (عود درد و تعداد دفعات تجویز اوپیوئید و NSAID در روزهای اول تا سوم) در لحظه پذیرش وجود ندارند و **نباید** استفاده شوند. **(امتیازی)** همین مدل را در سناریوی ۷۲ ساعت پس از پذیرش (همه ستون‌ها) هم اجرا کنید و تفاوت نتایج را توضیح دهید.

۱.۷ مسیر پیشنهادی انجام پروژه

اگر نمی‌دانید از کجا شروع کنید، این چهار مرحله را به ترتیب جلو بروید:

۱. **آشنایی با داده:** داده را بارگذاری کنید، ستون‌های ممنوع را حذف کنید، مجموعه آزمون را جدا کنید (بخش ۹) و روی داده آموزش نرخ گمشدگی هر ستون، توزیع چند ویژگی و شیوع سه پیامد را بررسی کنید.

۲. **مدل‌های پایه:** مدل پایه مبتنی بر شیوع و رگرسیون لجستیک را داخل یک Pipeline بسازید و با اعتبارسنجی متقابل ارزیابی کنید. این نقطه مرجع شماست.

۳. **بهبود و کالیبراسیون:** مدل درختی را اضافه کنید، ابرپارامترها را تنظیم کنید، مدل نهایی را انتخاب و کالیبره کنید و آستانه تصمیم را تعیین کنید.

۴. **ارزیابی نهایی و گزارش:** مدل نهایی را یک بار روی مجموعه آزمون ارزیابی کنید، آن را تفسیر کنید، به سوالات پاسخ دهید و گزارش را بنویسید.

۸ ورودی و خروجی

مسئله که روشن شد، باید دقیق مشخص کنیم مدل چه چیزی دریافت می‌کند و چه چیزی تحویل می‌دهد.

ورودی: ویژگی‌های مجاز زمان پذیرش برای هر بیمار (بدون شناسه بیمار و بدون هیچ‌کدام از ۱۲ پیامد). هیچ پیامدی نمی‌تواند ورودی پیامد دیگر باشد، چون همه آن‌ها در آینده رخ می‌دهند.

خروجی: برای هر بیمار سه عدد بین ۰ و ۱، یعنی احتمال وقوع هر یک از سه پیامد اصلی (برای LET_IS، احتمال فوت طبق تعریف باینری بخش ۱.۴). این احتمال‌ها از هم مستقل‌اند و لازم نیست جمعشان ۱ شود. علاوه بر احتمال، برای هر پیامد یک آستانه تصمیم مستدل پیشنهاد دهید (بخش ۱۲). خروجی روی مجموعه آزمون را در یک فایل CSV با قالب زیر ذخیره کنید (اگر بخش امتیازی را انجام می‌دهید، ستون پیامدهای دیگر را هم اضافه کنید):

```
ID,LET_IS,ZSN,FIBR_PREDS
1043,0.22,0.31,0.12
```

۹ تقسیم‌بندی داده

پیش از ساختن هر مدلی باید داده را تقسیم کنید، چون هر تصمیمی که با دیدن داده آزمون گرفته شود نتیجه ارزیابی را خوش‌بینانه می‌کند. روش تقسیم را در گزارش شرح دهید و این مراحل را رعایت کنید:

۱. **جدا کردن مجموعه آزمون:** در ابتدای کار، ٪۲۰ داده (حدود ۳۴۰ بیمار) را به عنوان مجموعه آزمون جدا کنید. تقسیم را بر اساس مرگ طبقه‌بندی‌شده (stratified) انجام دهید، یعنی در train_test_split پارامتر stratify را برابر ستون مرگ بگذارید. با random_state ثابت تقسیم کنید.

۲. **قفل کردن مجموعه آزمون:** این مجموعه فقط **یک بار** و در انتها برای ارزیابی مدل نهایی استفاده می‌شود. انتخاب مدل، تنظیم ابرپارامتر و انتخاب آستانه همه باید بدون نگاه به آن انجام شوند.

۳. **اعتبارسنجی متقابل روی ٪۸۰ باقی‌مانده:** برای مقایسه مدل‌ها و تنظیم ابرپارامترها از اعتبارسنجی متقابل طبقه‌بندی‌شده ۵-fold (StratifiedKFold) استفاده کنید و نتایج را به صورت میانگین و انحراف معیار ۵ fold گزارش کنید.

۴. **پیش‌پردازش درون Pipeline:** جایگذاری داده گمشده، نرمال‌سازی، انتخاب ویژگی و نمونه‌برداری مجدد (SMOTE، undersampling) فقط باید روی داده آموزش هر fold یاد گرفته شوند و سپس روی داده ارزیابی اعمال شوند. ساده‌ترین راه این است که همه این مراحل را داخل یک Pipeline در scikit-learn بگذارید (برای نمونه‌برداری مجدد از imblearn.pipeline.Pipeline).

این مهم‌ترین قانون پروژه است.

(امتیازی) تکرار اعتبارسنجی متقابل با چند seed مختلف (RepeatedStratifiedKFold)، اعتبارسنجی متقابل تودرتو (nested CV) برای گزارش بدون سوگیری بعد از تنظیم ابرپارامتر، و تقسیم طبقه‌بندی‌شده چندبرچسبی (iterative stratification) اگر پیامدهای دیگر را هم پیش‌بینی می‌کنید.

۱۰ الزامات مدل‌سازی

انتخاب روش‌ها تا حد زیادی با خود شماست، اما برای اینکه مقایسه‌ها معنادار باشند و نتایج قابل دفاع، چند الزام مشترک برای همه دانشجویان تعیین شده است.

۱.۱۰ مدل‌های اجباری

هر دانشجو باید سه مدل زیر را برای هر سه پیامد پیاده‌سازی و مقایسه کند. هر مدل به یک سوال مشخص پاسخ می‌دهد.

جدول ۱.۱۰: مدل‌های اجباری

مدل	شرط	سوالی که پاسخ می‌دهد
۰. مدل پایه مبتنی بر شیوع	پیش‌بینی شیوع هر پیامد برای همه بیماران (DummyClassifier)	مدل شما چقدر بهتر از هیچ است؟
۱. مدل خطی	رگرسیون لجستیک (با منظم‌سازی)	یک رابطه ساده و شفاف چقدر از مسئله را حل می‌کند؟
۲. مدل درختی تجمیعی	جنگل تصادفی یا بوستینگ (LightGBM، XGBoost، CatBoost)	تعاملات غیرخطی چقدر کمک می‌کنند؟

مدل پایه مبتنی بر شیوع چیست؟ این ساده‌ترین مدل ممکن است و عمداً از هیچ ویژگی‌ای استفاده نمی‌کند. «شیوع» یک پیامد یعنی نسبت بیمارانی از داده آموزش که آن پیامد را داشته‌اند. این مدل همین عدد را به عنوان احتمال، برای همه بیماران پیش‌بینی می‌کند. مثلاً چون حدود ۱۶٪ بیماران داده آموزش فوت کرده‌اند، مدل پایه برای هر بیمار جدید، بدون نگاه کردن به سن، فشار خون یا هر اطلاعات دیگری، می‌گوید «احتمال مرگ ۰/۱۶». برای ZSN این عدد حدود ۰/۲۳ و برای FIBR_PREDS حدود ۰/۱۰ است. در scikit-learn این مدل با DummyClassifier(strategy="prior") ساخته می‌شود و مثل هر مدل دیگری فقط روی داده آموزش fit می‌شود.

چرا به آن نیاز داریم؟ چون مدل پایه هیچ اطلاعاتی از بیمار استفاده نمی‌کند، نشان می‌دهد که «بدون یادگیری» چه نتیجه‌ای به دست می‌آید. هر مدلی که واقعاً چیزی از ویژگی‌ها یاد گرفته باشد باید به وضوح از آن بهتر باشد. اعداد مرجع این مدل را می‌توان از پیش حساب کرد:

- AUROC آن برابر ۰/۵ است، چون به همه بیماران یک امتیاز یکسان می‌دهد و هیچ ترتیبی بین آن‌ها ایجاد نمی‌کند.
- AUPRC آن تقریباً برابر شیوع پیامد است (مثلاً حدود ۰/۱۶ برای مرگ)؛ به همین دلیل یک AUPRC برابر ۰/۳۰ برای مرگ، با اینکه عدد کوچکی به نظر می‌رسد، تقریباً دو برابر مدل پایه است.
- Brier score آن برابر $\pi(1-\pi)$ است که π شیوع پیامد است (حدود ۰/۱۳ برای مرگ). Brier skill score مدل‌های شما دقیقاً نسبت به همین عدد سنجیده می‌شود.
- اگر احتمال آن را با آستانه ۰/۵ به برچسب تبدیل کنید، همه بیماران «منفی» پیش‌بینی می‌شوند و accuracy حدود ۸۴٪ به دست می‌آید، در حالی که حتی یک بیمار پرخطر هم شناسایی نشده است. این مثال به خوبی نشان می‌دهد چرا accuracy معیار مناسبی برای این مسئله نیست.

(امتیازی) یک مدل چندبرچسبی که از همبستگی بین پیامدها استفاده کند (Classifier Chain، شبکه عصبی چندوظیفه‌ای و ...) و مقایسه آن با مدل‌های جداگانه.

۲.۱۰ مدل نهایی

انتخاب مدل نهایی با شماست. می‌تواند یکی از مدل‌های بالا، ترکیبی از آن‌ها (ensemble)، یا هر مدل دیگری باشد. اما مدل نهایی باید روی این دیتاست **نتیجه معقول** بدهد. نتیجه معقول یعنی:

- برای هر سه پیامد از مدل پایه مبتنی بر شیوع بهتر باشد: AUPRC بالاتر از شیوع پیامد و Brier score کمتر از مدل پایه.
- احتمال‌هایش کالیبره باشد: نمودار کالیبراسیون نزدیک قطر.
- اگر مدل پیچیده‌ای انتخاب می‌کنید که از مدل درختی یا خطی بهتر نیست، توضیح دهید چرا آن را ترجیح داده‌اید.

۳.۱۰ قوانین خط لوله

۱. همه قواعد بخش ۹ رعایت شوند.

۲. اگر از نمونه‌برداری مجدد یا وزن‌دهی کلاس استفاده می‌کنید، احتمال‌های خروجی باید دوباره کالیبره شوند (بخش ۱۱).

۳. استفاده از ستون‌های ممنوع جدول ۳.۳، و استفاده از یک پیامد برای پیش‌بینی پیامد دیگر، ممنوع است.

۴. برای مدل درختی، مهم‌ترین ویژگی‌ها را با SHAP (نمودار summary plot) برای پیش‌بینی مرگ نشان دهید و در چند جمله توضیح دهید. **(امتیازی)** تفسیر محلی برای دو بیمار نمونه.

۵. کد با random_state ثابت قابل بازتولید باشد.

۱۱ کالیبراسیون

خروجی مدل شما احتمال است، نه فقط یک برچسب. پس لازم است مطمئن شوید این احتمال‌ها قابل اعتمادند. این بخش توضیح می‌دهد کالیبراسیون چیست، چطور سنجیده می‌شود و با چه الگوریتم‌هایی می‌توان آن را بهبود داد.

۱.۱۱ کالیبراسیون چیست و چرا مهم است

مدلی کالیبره است که احتمال‌هایش به معنای واقعی احتمال باشند. به زبان ریاضی، برای هر مقدار p:

$$P(Y = 1 \mid \hat{p}(X) = p) = p$$

یعنی از میان همه بیمارانی که مدل برایشان احتمال ٪۲۰ پیش‌بینی کرده، باید حدود ٪۲۰ واقعاً آن پیامد را داشته باشند.

کالیبراسیون و قدرت تمایز (discrimination) دو چیز متفاوت‌اند. AUROC فقط به ترتیب بیماران حساس است؛ اگر همه احتمال‌ها را نصف کنید، AUROC تغییر نمی‌کند ولی احتمال‌ها کاملاً غلط می‌شوند. در کاربرد بالینی، پزشک به خود عدد احتمال تکیه می‌کند (مثلاً «٪۳۵ احتمال مرگ»)، پس مدل غیرکالیبره حتی با AUROC بالا خطرناک است.

چه چیزی کالیبراسیون را خراب می‌کند:

- **نمونه‌برداری مجدد و وزن‌دهی کلاس:** اگر با undersampling نسبت کلاس‌ها را ۱:۱ کنید، مدل یاد می‌گیرد که شیوع پیامد ٪۵۰ است و احتمال‌ها به شدت بیش‌برآورد می‌شوند.
- **مدل‌های بوستینگ و SVM:** خروجی این مدل‌ها معمولاً احتمال واقعی نیست (SVM اصلاً احتمال تولید نمی‌کند).
- **بیش‌برازش:** مدل بیش‌برازش‌شده بیش از حد مطمئن است و احتمال‌ها را به ۰ و ۱ می‌چسباند.
- **جنگل تصادفی:** به دلیل میانگین‌گیری، احتمال‌ها را از ۰ و ۱ دور و به سمت وسط می‌کشد.

۲.۱۱ سنجش کالیبراسیون

- **نمودار کالیبراسیون (reliability diagram):** بیماران را بر اساس احتمال پیش‌بینی‌شده در چند گروه (مثلاً ۱۰ گروه یا بر اساس چندک) قرار دهید. برای هر گروه میانگین احتمال پیش‌بینی‌شده را در محور افقی و نسبت واقعی موارد مثبت را در محور عمودی رسم کنید. مدل کامل روی قطر قرار می‌گیرد. برای پیامدهای نادر از گروه‌بندی بر اساس چندک (strategy="quantile") استفاده کنید، چون بیشتر بیماران احتمال پایین دارند.

- **(امتیازی) خطای کالیبراسیون مورد انتظار (ECE):** میانگین وزنی فاصله پیش‌بینی و واقعیت در گروه‌ها:

$$\mathrm{ECE} = \sum_{b=1}^{B} \frac{n_b}{N} \left| \bar{y}_b - \bar{p}_b \right|$$

که در آن n_b تعداد بیماران گروه b، $\bar{y}_b$ نسبت واقعی و $\bar{p}_b$ میانگین احتمال پیش‌بینی‌شده است.

- **(امتیازی) شیب و عرض از مبدأ کالیبراسیون:** یک رگرسیون لجستیک از برچسب واقعی روی $\mathrm{logit}(\hat{p})$ برازش دهید:

$$\mathrm{logit}\, P(Y=1) = a + b \cdot \mathrm{logit}(\hat{p})$$

مدل کالیبره $a = 0$ و $b = 1$ دارد. اگر $b < 1$ باشد، پیش‌بینی‌ها بیش از حد افراطی‌اند (نشانه بیش‌برازش)؛ اگر $b > 1$ باشد، بیش از حد محتاط‌اند. عرض از مبدأ (با $b = 1$ ثابت) نشان می‌دهد مدل به طور کلی بیش‌برآورد یا کم‌برآورد می‌کند.

۳.۱۱ الگوریتم‌های کالیبراسیون

از روش‌های زیر فقط **مقیاس‌بندی پلات** اجباری است. بقیه روش‌ها برای آشنایی آمده‌اند و استفاده و مقایسه آن‌ها **(امتیازی)** است.

همه روش‌های زیر یک تابع یکنوا g یاد می‌گیرند که خروجی خام مدل s را به احتمال کالیبره $g(s)$ تبدیل کند. این تابع باید روی داده‌ای جدا از داده آموزش مدل برازش شود.

۱. **مقیاس‌بندی پلات (Platt scaling):** یک رگرسیون لجستیک دوپارامتری روی خروجی مدل:

$$g(s) = \frac{1}{1 + \exp(-(As + B))}$$

پارامترهای A و B با بیشینه‌سازی درست‌نمایی روی داده کالیبراسیون به دست می‌آیند. چون فقط دو پارامتر دارد، با داده کم هم پایدار است و برای پیامدهای نادر این دیتاست انتخاب مناسبی است. محدودیتش این است که فرض می‌کند انحراف کالیبراسیون شکل سیگموید دارد.

۲. **رگرسیون ایزوتونیک (isotonic regression):** یک تابع پله‌ای یکنوای غیرپارامتری که مجموع مربعات خطا را کمینه می‌کند:

$$\min_{g\text{ یکنوا}} \sum_i (y_i - g(s_i))^2$$

و با الگوریتم Pool Adjacent Violators حل می‌شود. هر شکلی از انحراف را اصلاح می‌کند، اما به داده زیاد نیاز دارد و با چند ده مورد مثبت به راحتی بیش‌برازش می‌شود. برای پیامدهایی مثل نارسایی مزمن قلب (۳۹۴ مورد) قابل استفاده است ولی برای تاکی‌کاردی فوق‌بطنی (۲۰ مورد) توصیه نمی‌شود.

۳. **کالیبراسیون بتا (beta calibration):** تعمیم سه‌پارامتری پلات:

$$g(s) = \frac{1}{1 + \exp(-(a \ln s - b \ln(1-s) + c))}$$

برای مدل‌هایی که احتمال‌هایشان نزدیک ۰ یا ۱ متراکم است (مثل بوستینگ و بیز ساده) از پلات انعطاف‌پذیرتر و از ایزوتونیک پایدارتر است.

۴. **مقیاس‌بندی دما (temperature scaling):** برای شبکه‌های عصبی، لاجیت خروجی z را بر یک پارامتر $T > 0$ تقسیم می‌کنیم: $g(z) = \sigma(z/T)$. اگر $T > 1$ باشد مدل محتاط‌تر می‌شود. چون فقط یک پارامتر دارد، ترتیب پیش‌بینی‌ها و در نتیجه AUROC را تغییر نمی‌دهد.

۵. **اصلاح احتمال پیشین پس از نمونه‌برداری مجدد (prior correction):** اگر کلاس منفی را با نرخ β زیرنمونه‌برداری کرده باشید (یعنی فقط کسر β از منفی‌ها را نگه داشته باشید)، احتمال درست از احتمال مدل p_s این‌گونه به دست می‌آید:

$$p = \frac{\beta\, p_s}{\beta\, p_s - p_s + 1}$$

این روش بدون داده کالیبراسیون اضافه کار می‌کند ولی فقط اثر تغییر توزیع کلاس را جبران می‌کند، نه سایر منابع خطا.

پیاده‌سازی: در scikit-learn از CalibratedClassifierCV با method="sigmoid" (پلات) یا method="isotonic" استفاده کنید. این کلاس با cross-fitting کالیبراسیون را روی داده‌ای جدا از داده آموزش هر زیرمدل انجام می‌دهد. برای کالیبراسیون

بتا کتابخانه betacal در دسترس است.

خواسته پروژه: مدل نهایی را برای هر سه پیامد با مقیاس‌بندی پلات (CalibratedClassifierCV با "sigmoid"=(method کالیبره کنید و نمودار کالیبراسیون و Brier score را **قبل و بعد از کالیبراسیون** گزارش کنید. **(امتیازی)** مقایسه با روش ایزوتونیک و گزارش ECE و شیب کالیبراسیون.

۱۲ معیارهای ارزیابی

پس از ساختن و کالیبره کردن مدل‌ها، باید آن‌ها را با معیارهایی بسنجید که با ماهیت نامتوازن این مسئله سازگار باشند.

معیارهای اجباری این پروژه AUPRC، AUROC، Brier score و معیارهای وابسته به آستانه (ماتریس درهم‌ریختگی، حساسیت، ویژگی و دقت مثبت) هستند. آن‌ها را برای هر پیامد جداگانه گزارش کنید. معیار اصلی برای انتخاب مدل AUPRC است. Accuracy به عنوان معیار اصلی پذیرفته نمی‌شود. بخش‌هایی که با **(امتیازی)** مشخص شده‌اند اختیاری‌اند. در فرمول‌ها $y_i \in \{0,1\}$ برچسب واقعی، $\hat{p}_i$ احتمال پیش‌بینی‌شده، N تعداد بیماران و π شیوع پیامد است.

۱.۱۲ مساحت زیر منحنی دقت‌ـبازیابی (AUPRC)

منحنی دقت‌ـبازیابی برای همه آستانه‌های ممکن، دقت (Precision $= \frac{TP}{TP+FP}$) را در برابر بازیابی (Recall $= \frac{TP}{TP+FN}$) رسم می‌کند. مساحت زیر آن معمولاً با Average Precision محاسبه می‌شود:

$$\mathrm{AP} = \sum_k (R_k - R_{k-1})\, P_k$$

چرا مهم است: این معیار فقط به نحوه رتبه‌بندی موارد مثبت توجه دارد و از تعداد زیاد منفی‌های درست تأثیر نمی‌گیرد. به همین دلیل برای پیامدهای نادر حساس‌ترین معیار است. **تفسیر:** مقدار AUPRC یک مدل تصادفی برابر شیوع پیامد (π) است، نه ۰/۵. پس AUPRC برابر ۰/۱۵ برای تاکی‌کاردی فوق‌بطنی (شیوع ۱/۲٪) عملکرد خوبی است، ولی همین عدد برای نارسایی مزمن قلب (شیوع ۲۳٪) بدتر از تصادفی است. همیشه AUPRC را کنار شیوع و به صورت نسبت AUPRC/π هم گزارش کنید.

۲.۱۲ مساحت زیر منحنی ROC (AUROC)

منحنی ROC نرخ مثبت درست (TPR) را در برابر نرخ مثبت کاذب (FPR $= \frac{FP}{FP+TN}$) رسم می‌کند. AUROC برابر احتمال این است که یک بیمار مثبت تصادفی، احتمال بالاتری از یک بیمار منفی تصادفی بگیرد:

$$\text{AUROC} = P(\hat{p}_+ > \hat{p}_-)$$

تفسیر: ۰/۵ یعنی تصادفی و ۱ یعنی تمایز کامل. معمولاً بالای ۰/۷ قابل قبول و بالای ۰/۸ خوب تلقی می‌شود. **محدودیت:** در عدم توازن شدید خوش‌بینانه است، چون FPR با تعداد زیاد منفی‌ها کوچک می‌ماند. به کالیبراسیون هم حساس نیست. برای مقایسه با مقالات و برای سنجش تمایز کلی مفید است، ولی به تنهایی کافی نیست.

۳.۱۲ Brier score و Brier Skill Score

میانگین مربع خطای احتمال:

$$\text{BS} = \frac{1}{N}\sum_{i=1}^{N}(\hat{p}_i - y_i)^2$$

این یک قاعده امتیازدهی سره (proper scoring rule) است، یعنی فقط وقتی کمینه می‌شود که مدل احتمال‌های واقعی را گزارش کند. بنابراین هم تمایز و هم کالیبراسیون را با هم می‌سنجد. **مشکل:** برای پیامد نادر، مدل پایه مبتنی بر شیوع هم Brier کوچکی دارد (برابر $\pi(1-\pi)$). برای همین آن را نسبت به مدل پایه نرمال کنید:

$$\text{BSS} = 1 - \frac{\text{BS}_{\text{model}}}{\text{BS}_{\text{baseline}}}, \qquad \text{BS}_{\text{baseline}} = \pi(1-\pi)$$

تفسیر: BSS برابر ۰ یعنی هم‌سطح مدل پایه مبتنی بر شیوع، مقدار منفی یعنی بدتر از آن، و ۱ یعنی کامل.

۴.۱۲ Log loss (امتیازی)

$$\text{LL} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \ln \hat{p}_i + (1-y_i)\ln(1-\hat{p}_i)\right]$$

این هم یک قاعده امتیازدهی سره است و مدل‌هایی را که با اطمینان زیاد اشتباه می‌کنند (مثلاً احتمال ۰/۰۱ برای بیماری که فوت کرده) به شدت جریمه می‌کند. آن را در کنار Brier گزارش کنید.

۵.۱۲ معیارهای وابسته به آستانه

برای تصمیم‌گیری (مثلاً «این بیمار به پایش ویژه نیاز دارد») باید احتمال را با یک آستانه t به پیش‌بینی دودویی تبدیل کرد. برای آستانه انتخابی خود این معیارها را گزارش کنید:

- **حساسیت (Sensitivity، Recall)**: $\frac{TP}{TP+FN}$؛ چه کسری از بیمارانی که واقعاً دچار پیامد می‌شوند شناسایی شده‌اند.
- **ویژگی (Specificity)**: $\frac{TN}{TN+FP}$؛ چه کسری از بیماران سالم درست تشخیص داده شده‌اند.
- **ارزش اخباری مثبت (PPV، Precision)**: $\frac{TP}{TP+FP}$؛ از هر ۱۰ هشدار مدل، چند تا درست است. این عدد مستقیماً به شیوع وابسته است و برای پیامدهای نادر حتی با ویژگی بالا پایین می‌ماند.
- **F1**: $\frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision}+\text{Recall}}$؛ فقط برای کلاس مثبت گزارش شود، نه به صورت وزنی (weighted F1)، چون نسخه وزنی تحت سلطه کلاس اکثریت است.

انتخاب آستانه: آستانه ۰٫۵ پیش‌فرض برای پیامدهای نادر تقریباً همیشه نادرست است. آستانه را با یکی از این روش‌ها، فقط روی داده آموزش یا اعتبارسنجی، انتخاب کنید و دلیلش را توضیح دهید:

- رسیدن به حساسیت حداقلی مشخص (مثلاً ٪۸۰) با بیشترین ویژگی ممکن.
- بر اساس هزینه: اگر هزینه از دست دادن یک بیمار پرخطر C_{FN} و هزینه یک هشدار کاذب C_{FP} باشد، برای مدل کالیبره آستانه بهینه $t^* = \frac{C_{FP}}{C_{FP}+C_{FN}}$ است.

۶.۱۲ تحلیل منحنی تصمیم (Decision Curve Analysis) (امتیازی)

این روش می‌سنجد استفاده از مدل در عمل سودمند است یا نه. برای هر آستانه t، سود خالص (Net Benefit) این‌گونه تعریف می‌شود:

$$\text{NB}(t) = \frac{TP}{N} - \frac{FP}{N} \cdot \frac{t}{1-t}$$

عبارت $\frac{t}{1-t}$ وزن هر هشدار کاذب را نسبت به هر شناسایی درست نشان می‌دهد. منحنی $\text{NB}(t)$ مدل را در بازه‌ای از آستانه‌های معقول (مثلاً ٪۵ تا ٪۴۰) رسم کنید و با دو راهبرد مرجع مقایسه کنید: «همه را درمان کن» و «هیچ‌کس را درمان نکن» (که سود خالص آن صفر است). مدل فقط در آستانه‌هایی مفید است که منحنی آن بالاتر از هر دو باشد.

۷.۱۲ بازه اطمینان و مقایسه مدل‌ها

در بخش اجباری، گزارش میانگین و انحراف معیار ۵ fold کافی است. **(امتیازی)** بازه اطمینان ۹۵٪ را گزارش کنید: یا با bootstrap روی مجموعه آزمون (حداقل ۱۰۰۰ بار نمونه‌گیری با جایگذاری)، یا از پراکندگی نتایج در اعتبارسنجی متقابل تکراری. برای ادعای برتری یک مدل بر دیگری، تفاوت دو مدل را روی همان foldها یا همان نمونه‌های bootstrap مقایسه کنید (مقایسه جفتی)، نه اینکه فقط هم‌پوشانی بازه‌ها را نگاه کنید. برای مقایسه AUROC دو مدل روی یک مجموعه، آزمون DeLong هم قابل استفاده است.

۱۳ سوالات

علاوه بر ساختن مدل، باید نشان دهید رفتار آن و محدودیت‌های داده را می‌فهمید. به چهار سوال اجباری زیر در گزارش پاسخ دهید. پاسخ هر سوال باید با یک آزمایش کوچک روی همین دیتاست همراه باشد، نه فقط با استدلال.

۱. **نشت اطلاعات:** یک بار SMOTE (یا جایگذاری داده گمشده) را قبل از تقسیم داده و یک بار درون Pipeline انجام دهید. نتیجه اعتبارسنجی متقابل چقدر فرق می‌کند؟ کدام عدد قابل اعتماد است و چرا؟

۲. **احتمال پس از نمونه‌برداری مجدد:** بعد از undersampling با نسبت ۱:۱، میانگین احتمال مرگ پیش‌بینی‌شده چقدر است و شیوع واقعی چقدر؟ این احتمال‌ها را با یک روش بخش ۱۱ اصلاح کنید و نتیجه را مقایسه کنید.

۳. **انتخاب آستانه:** فرض کنید از دست دادن یک بیمار پرخطر ۱۰ برابر بدتر از یک هشدار کاذب است. آستانه مناسب برای مرگ چقدر است و با آن، از هر ۱۰۰ بیمار چند هشدار داده می‌شود و چند مورد فوت شناسایی می‌شود؟

۴. **پیش‌بینی در برابر علیت:** در مقاله Guo et al.، «مصرف هپارین در ICU» از مهم‌ترین ویژگی‌ها بوده است. آیا این یعنی هپارین باعث عارضه می‌شود؟ در مدل خودتان هم یک ویژگی مهم را پیدا کنید که احتمالاً «علت» نیست و توضیح دهید.

سوالات امتیازی

۵. با ۲۰ مورد مثبت تاکی‌کاردی فوق‌بطنی، آیا این پیامد اصلاً قابل پیش‌بینی است؟ بازه اطمینان AUROC را گزارش کنید.

۶. نتیجه شما در ۵ بار تکرار اعتبارسنجی با seedهای مختلف چقدر تغییر می‌کند؟ آیا تفاوت دو مدل برترتان از این نوسان بیشتر است؟

۷. پارگی میوکارد در این دیتاست تقریباً همیشه به مرگ منجر شده. آیا مدل شما این سازگاری را رعایت می‌کند؟

۸. آیا گمشده بودن یک آزمایش خودش اطلاعات دارد؟ مدل را با و بدون شاخص گمشدگی (missing indicator) مقایسه کنید.

۹. عملکرد مدل نهایی در زنان و مردان و در بیماران بالای ۷۰ سال چقدر تفاوت دارد؟

۱۰. این داده مربوط به یک بیمارستان در روسیه در دهه ۱۹۹۰ است. برای استفاده از مدل شما در یک بیمارستان ایرانی امروز، چه چیزی باید تغییر کند؟

منابع

- Myocardial Infarction Complications, UCI Machine Learning Repository
- Yavru, I.B., Yılmaz Gündüz, S. (2022). Predicting Myocardial Infarction Complications and Outcomes with Deep Learning.
- Golovenkin, S.E. et al. Trajectories, bifurcations and pseudotime in large clinical datasets: applications to myocardial infarction and diabetes data.
- Vicente, A.L.G. et al. Explainable LightGBM Approach for Predicting Myocardial Infarction Mortality.
- Ghafari, R. et al. (2023). Prediction of the Fatal Acute Complications of Myocardial Infarction via Machine Learning Algorithms.
- Makhmudov, F. et al. (2025). A Multitask Deep Learning Model for Predicting Myocardial Infarction Complications.
- Guo, D. et al. (2026). Predicting complications and mortality in myocardial infarction patients using a graph neural network model.

آ واژه‌نامه ستون‌های ورودی

در این پیوست ستون‌های ورودی دیتاست دسته به دسته توضیح داده شده‌اند. برای فهم کلی دسته‌ها، جدول ۱.۳ را ببینید.

آ.۱ مشخصات جمعیتی و پیشینه بالینی (Demographic & Clinical History)

- AGE: سن بیمار (بر حسب سال)
- SEX: جنسیت (۰ = زن، ۱ = مرد)
- INF_ANAM: تعداد سکته‌های قلبی قبلی در سابقه پزشکی (۰ تا ۳ و بیشتر)
- STENOK_AN: سابقه آنژین ورزشی (Exertional Angina، درد قفسه سینه ناشی از کاهش خون‌رسانی به قلب در حین فعالیت فیزیکی)، بر حسب سال گذشته
- FK_STENOK: کلاس عملکردی آنژین صدری در سال گذشته (Functional Class of Angina) بر اساس طبقه‌بندی انجمن قلب کانادا (CCS). این طبقه‌بندی نشان می‌دهد درد قفسه سینه (آنژین، یعنی کاهش جریان خون به عضله قلب) با چه میزان فعالیت بدنی ایجاد می‌شود:
  - 0: بدون آنژین صدری در سال گذشته.
  - 1 (کلاس I): فعالیت‌های معمول روزانه درد ایجاد نمی‌کند؛ درد فقط با فعالیت شدید، سریع یا طولانی رخ می‌دهد.
  - 2 (کلاس II): محدودیت خفیف؛ درد هنگام راه رفتن یا بالا رفتن سریع از پله، راه رفتن در سربالایی، پس از غذا، در هوای سرد، یا در حالت استرس و در ساعات اولیه پس از بیدار شدن ایجاد می‌شود.
  - 3 (کلاس III): محدودیت قابل توجه؛ درد با راه رفتن یک تا دو بلوک در سطح صاف یا بالا رفتن از یک طبقه پله با سرعت معمولی ایجاد می‌شود.
  - 4 (کلاس IV): ناتوانی در انجام هیچ فعالیت بدنی بدون ناراحتی؛ درد ممکن است حتی در حالت استراحت هم رخ دهد.
- IBS_POST: بیماری ایسکمیک قلبی (CHD: Coronary Heart Disease، تنگ‌شدگی عروق تغذیه‌کننده قلب) در هفته‌های اخیر (۰ = نبوده، ۱ = آنژین ورزشی، ۲ = آنژین ناپایدار)
- IBS_NASL: سابقه خانوادگی بیماری ایسکمیک قلبی

- GB: فشار خون اساسی (Essential Hypertension، فشار خون بالای اولیه بدون علت زمینه‌ای مشخص)، مرحله ۰ تا ۳
- SIM_GIPERT: فشار خون علامتی (Symptomatic Hypertension، فشار خون بالا ناشی از یک بیماری زمینه‌ای)
- DLIT_AG: مدت ابتلا به فشار خون بالا (سال)
- ZSN_A: نارسایی مزمن قلبی (Chronic Heart Failure، کاهش توانایی پمپاژ قلب در طول زمان) در سابقه پزشکی، مرحله ۰ تا IIB

آ.۲ سابقه آریتمی (Arrhythmia History)

آریتمی (Arrhythmia) به هرگونه اختلال در ریتم طبیعی ضربان قلب گفته می‌شود — چه از نظر سرعت (بیش از حد تند یا کند) و چه از نظر الگوی ضربان (نامنظم). ویژگی‌های nr نشان‌دهنده سابقه اختلالات ریتم قلبی در تاریخچه پزشکی بیمار (پیش از بستری) هستند:

- nr11: سابقه هر نوع آریتمی (Any Arrhythmia)
- nr01: انقباض زودرس دهلیزی (Premature Atrial Contraction، ضربان اضافی با منشأ دهلیز — حفره‌های فوقانی قلب)
- nr02: انقباض زودرس بطنی (Premature Ventricular Contraction، ضربان اضافی با منشأ بطن — حفره‌های تحتانی و اصلی پمپاژکننده قلب)
- nr03: پاروکسیسم فیبریلاسیون دهلیزی (Paroxysmal Atrial Fibrillation؛ پاروکسیسم یعنی حمله ناگهانی که خودبه‌خود شروع و تمام می‌شود؛ فیبریلاسیون دهلیزی یعنی تخلیه‌های الکتریکی آشفته و نامنظم در دهلیزها)
- nr04: فرم مزمن فیبریلاسیون دهلیزی (Persistent Atrial Fibrillation، آریتمی پایدار و دائمی)
- nr07: فیبریلاسیون بطنی (Ventricular Fibrillation، آریتمی خطرناک با از دست رفتن پمپاژ مؤثر — اورژانس بالینی)
- nr08: تاکی‌کاردی بطنی پاروکسیسمال (Ventricular Paroxysmal Tachycardia؛ تاکی‌کاردی یعنی ضربان بیش از ۱۰۰ در دقیقه؛ منشأ این نوع از بطن‌هاست)

۳.آ سابقه بلوک هدایتی (Conduction Block History)

سیستم هدایت الکتریکی قلب سیگنال ضربان را از دهلیزها به بطن‌ها منتقل می‌کند. بلوک هدایتی (Conduction Block) به اختلال یا قطع این مسیر گفته می‌شود که باعث کندی یا عدم همزمانی انقباض قلب می‌شود. ویژگی‌های np نشان‌دهنده سابقه این بلوک‌ها در تاریخچه پزشکی بیمار هستند:

- np01: بلوک AV درجه اول (First-degree AV Block؛ AV مخفف Atrioventricular یعنی ارتباط بین دهلیز و بطن؛ در درجه اول سیگنال با تأخیر منتقل می‌شود اما قطع نمی‌شود)
- np04: بلوک AV درجه سوم (Third-degree AV Block، قطع کامل سیگنال بین دهلیزها و بطن‌ها)
- np05: بلوک شاخه قدامی چپ (LBBB, Left Bundle Branch Block, Anterior Branch؛ شاخه‌های هیس مسیرهای سیم‌کشی داخل بطن‌ها هستند؛ LBBB یعنی بلوک در شاخه چپ)
- np07: بلوک ناقص شاخه چپ (Incomplete LBBB)
- np08: بلوک کامل شاخه چپ (Complete LBBB)
- np09: بلوک ناقص شاخه راست (Incomplete RBBB, Right Bundle Branch Block)
- np10: بلوک کامل شاخه راست (Complete RBBB)

۴.آ بیماری‌های همراه (Comorbidities)

این دسته شامل بیماری‌های غیرقلبی موجود در سابقه پزشکی بیمار است:

- endocr_01: دیابت ملیتوس (Diabetes Mellitus)
- endocr_02: چاقی (Obesity)
- endocr_03: پرکاری تیروئید (Thyrotoxicosis، ترشح بیش از حد هورمون تیروئید که باعث تسریع ضربان قلب می‌شود)
- zab_leg_01: برونشیت مزمن (Chronic Bronchitis)
- zab_leg_02: برونشیت مزمن انسدادی (Obstructive Chronic Bronchitis)

- zab_leg_03: آسم برونشی (Bronchial Asthma)
- zab_leg_04: پنومونی مزمن (Chronic Pneumonia)
- zab_leg_06: سل ریوی (Pulmonary Tuberculosis)

آ.۵ پارامترهای همودینامیک و وضعیت بدو پذیرش (Hemodynamic Parameters & Admission Status)

همودینامیک (Hemodynamics) به مطالعه جریان خون و فشار در عروق و حفره‌های قلب گفته می‌شود. پارامترهای این دسته وضعیت گردش خون بیمار را در لحظه پذیرش توصیف می‌کنند:

- S_AD_KBRIG: فشار خون سیستولیک (فشار هنگام انقباض قلب، عدد بالایی در اندازه‌گیری) توسط تیم اورژانس (mmHg)
- D_AD_KBRIG: فشار خون دیاستولیک (فشار هنگام استراحت قلب، عدد پایینی) توسط تیم اورژانس (mmHg)
- S_AD_ORIT: فشار خون سیستولیک در بخش ICU
- D_AD_ORIT: فشار خون دیاستولیک در بخش ICU
- O_L_POST: ادم ریوی (Pulmonary Edema، تجمع مایع در ریه به دلیل ضعف پمپاژ بطن چپ) هنگام پذیرش در ICU
- K_SH_POST: شوک کاردیوژنیک (Cardiogenic Shock، کاهش شدید برون‌ده قلبی که منجر به افت فشار خون و کاهش خون‌رسانی به اعضا می‌شود) هنگام پذیرش در ICU
- MP_TP_POST: پاروکسیسم فیبریلاسیون دهلیزی (حمله ناگهانی ریتم آشفته دهلیزی) در هنگام پذیرش یا مرحله پیش‌بیمارستانی
- SVT_POST: تاکی‌کاردی فوق‌بطنی (SVT: Supraventricular Tachycardia، ضربان سریع با منشأ بالاتر از بطن‌ها) در هنگام پذیرش
- GT_POST: تاکی‌کاردی بطنی هنگام پذیرش
- FIB_G_POST: فیبریلاسیون بطنی هنگام پذیرش

۶.آ یافته‌های نوار قلبی (Electrocardiographic Findings)

نوار قلبی یا ECG (Electrocardiogram) ابزاری است که فعالیت الکتریکی قلب را به صورت گرافیکی ثبت می‌کند. هر ضربان قلب یک موج الکتریکی مشخص ایجاد می‌کند که با حسگرهای چسبیده به بدن از زوایای مختلف اندازه‌گیری می‌شود — هر زاویه اندازه‌گیری را یک لید (Lead) می‌نامند. از روی شکل این امواج می‌توان محل آسیب، نوع آریتمی و بلوک‌های هدایتی را تشخیص داد.

محل انفارکتوس

در نوار قلبی، مجموعه موج QRS بازتاب انقباض بطن‌هاست. تغییر شکل این موج در لیدهای مختلف نشان می‌دهد کدام ناحیه از عضله قلب (میوکارد) آسیب دیده است. کدگذاری ستون: (۰ = بدون انفارکتوس، ۱ = انفارکتوس بدون تغییر QRS، ۲ = الگوی QR، ۳ = الگوی Qr، ۴ = الگوی QS)

- ant_im: انفارکتوس قدامی (Anterior MI)، لیدهای V1–V4 (دیواره جلویی قلب)
- lat_im: انفارکتوس جانبی (Lateral MI)، لیدهای V5–V6, I, AVL (دیواره کناری چپ)
- inf_im: انفارکتوس تحتانی (Inferior MI)، لیدهای III, AVF, II (دیواره پایینی)
- post_im: انفارکتوس خلفی (Posterior MI)، لیدهای V7–V9 (دیواره پشتی)
- IM_PG_P: انفارکتوس بطن راست (Right Ventricular MI)

ریتم ECG هنگام پذیرش

این ویژگی‌ها ریتم قلبی بیمار را در لحظه پذیرش، بر اساس خواندن نوار قلبی، توصیف می‌کنند:

- ritm_ecg_p_01: ریتم سینوسی طبیعی (۶۰–۹۰ ضربه در دقیقه؛ سینوسی یعنی ضربان از گره سینوس‌آتریال، ضربان‌ساز طبیعی قلب، شروع می‌شود)
- ritm_ecg_p_02: فیبریلاسیون دهلیزی (Atrial Fibrillation)
- ritm_ecg_p_04: ریتم دهلیزی (Atrial Rhythm، ضربان از محلی در دهلیز غیر از گره سینوسی شروع می‌شود)
- ritm_ecg_p_06: ریتم ایدیوبطنی (Idioventricular Rhythm، ضربان از بطن کنترل می‌شود — معمولاً کند و نشانه مشکل جدی)

- ritm_ecg_p_07: تاکی‌کاردی سینوسی (ریتم سینوسی با ضربان بالای ۹۰)
- ritm_ecg_p_08: برادی‌کاردی سینوسی (Sinus Bradycardia، ریتم سینوسی با ضربان زیر ۶۰)

آریتمی در ECG هنگام پذیرش

آریتمی‌های مشاهده‌شده در نوار قلبی لحظه پذیرش بیمار:

- n_r_ecg_p_01: انقباض زودرس دهلیزی
- n_r_ecg_p_02: انقباض زودرس دهلیزی مکرر (تعداد زیاد در هر دقیقه)
- n_r_ecg_p_03: انقباض زودرس بطنی
- n_r_ecg_p_04: انقباض زودرس بطنی مکرر
- n_r_ecg_p_05: پاروکسیسم فیبریلاسیون دهلیزی
- n_r_ecg_p_06: فرم مزمن فیبریلاسیون دهلیزی
- n_r_ecg_p_08: تاکی‌کاردی فوق‌بطنی پاروکسیسمال
- n_r_ecg_p_09: تاکی‌کاردی بطنی پاروکسیسمال
- n_r_ecg_p_10: فیبریلاسیون بطنی

بلوک هدایتی در ECG هنگام پذیرش

بلوک‌های هدایتی مشاهده‌شده در نوار قلبی لحظه پذیرش:

- n_p_ecg_p_01: بلوک سینواتریال (Sinoatrial Block، اختلال در انتقال سیگنال از گره سینوسی به دهلیزها)
- n_p_ecg_p_03: بلوک AV درجه اول
- n_p_ecg_p_04: بلوک AV درجه دوم نوع ۱ (Mobitz I / Wenckebach، تأخیر تدریجی تا حذف یک ضربه)
- n_p_ecg_p_05: بلوک AV درجه دوم نوع ۲ (Mobitz II / Hay، حذف ناگهانی ضربه بدون تأخیر قبلی)
- n_p_ecg_p_06: بلوک AV درجه سوم (قطع کامل ارتباط الکتریکی بین دهلیز و بطن)

- n_p_ecg_p_07: بلوک شاخه قدامی چپ (LBBB)
- n_p_ecg_p_08: بلوک شاخه خلفی چپ
- n_p_ecg_p_09: بلوک ناقص شاخه چپ
- n_p_ecg_p_10: بلوک کامل شاخه چپ
- n_p_ecg_p_11: بلوک ناقص شاخه راست (RBBB)
- n_p_ecg_p_12: بلوک کامل شاخه راست

آ.۷ درمان فیبرینولیتیک (Fibrinolytic Therapy)

در سکته قلبی حاد، یک لخته خون رگ تغذیه‌کننده قلب را مسدود می‌کند. درمان فیبرینولیتیک (یا ترومبولیتیک، Thrombolytic Therapy) شامل تزریق داروهایی است که این لخته را حل می‌کنند و جریان خون را بازمی‌گردانند. واحد IU (International Unit) مقیاس اندازه‌گیری فعالیت زیست‌شناختی این داروهاست. این ویژگی‌ها نشان می‌دهند آیا بیمار داروی ترومبولیتیک دریافت کرده و با چه دوزی:

- fibr_ter_01: Celiasum با دوز ۷۵۰k IU
- fibr_ter_02: Celiasum با دوز ۱m IU
- fibr_ter_03: Celiasum با دوز ۳m IU
- fibr_ter_05: Streptase
- fibr_ter_06: Celiasum با دوز ۵۰۰k IU
- fibr_ter_07: Celiasum با دوز ۲۵۰k IU
- fibr_ter_08: Streptodecase با دوز ۵m.۱ IU

آ.۸ نتایج آزمایشگاهی (Laboratory Results)

آزمایش خون اطلاعات کمّی درباره وضعیت متابولیک و میزان آسیب بافتی فراهم می‌کند:

- GIPO_K: هیپوکالمی (Hypokalemia، پتاسیم سرم زیر ۳٫۵ mmol/L؛ کاهش پتاسیم خطر آریتمی را بالا می‌برد)
- K_BLOOD: مقدار پتاسیم سرم (mmol/L)
- GIPER_Na: هیپرناترمی (Hypernatremia، سدیم سرم بالای ۱۵۰ mmol/L)
- Na_BLOOD: مقدار سدیم سرم (mmol/L)
- ALT_BLOOD: آنزیم ALT (آلانین‌آمینوترانسفراز، Alanine Aminotransferase) (IU/L؛ افزایش آن نشانه آسیب کبدی است)
- AST_BLOOD: آنزیم AST (آسپارتات‌آمینوترانسفراز، Aspartate Aminotransferase) (IU/L؛ افزایش آن نشانه آسیب قلبی یا کبدی است)
- KFK_BLOOD: کراتین‌فسفوکیناز (CPK: Creatine Phosphokinase) (IU/L؛ مهم‌ترین نشانگر آسیب حاد به عضله قلب — در ساعات اول پس از سکته به سرعت بالا می‌رود)
- L_BLOOD: تعداد گلبول‌های سفید (WBC: White Blood Cell Count) (میلیارد در لیتر؛ افزایش آن نشانه التهاب یا عفونت است)
- ROE: سرعت رسوب گلبول قرمز (ESR: Erythrocyte Sedimentation Rate) (mm/hr؛ نشانگر غیراختصاصی التهاب در بدن)

آ.۹ زمان‌بندی و تکرار درد (Timing & Pain Recurrence)

- TIME_B_S: زمان از شروع حمله قلبی تا رسیدن به بیمارستان (۱ = کمتر از ۲ ساعت، ...، ۹ = بیش از ۳ روز؛ این فاصله زمانی تأثیر مستقیم بر مقدار آسیب قلبی دارد)
- R_AB_1_n: دفعات عود درد قفسه سینه در ساعات اول بستری
- R_AB_2_n: دفعات عود درد در روز دوم بستری
- R_AB_3_n: دفعات عود درد در روز سوم بستری

آ.۱۰ داروهای پیش‌بیمارستانی (Pre-hospital Medications by Emergency Team)

داروهایی که تیم اورژانس پیش از رسیدن به بیمارستان به بیمار تجویز کرده است:

- NA_KB: استفاده از داروهای اوپیوئید (Opioids، مسکن‌های قوی مانند مورفین که برای کنترل درد شدید قفسه سینه استفاده می‌شوند) توسط تیم اورژانس
- NOT_NA_KB: استفاده از NSAID (Non-Steroidal Anti-Inflammatory Drugs، داروهای ضدالتهاب غیراستروئیدی مانند آسپرین با دوز بالا) توسط تیم اورژانس
- LID_KB: استفاده از لیدوکائین (Lidocaine، داروی ضدآریتمی) توسط تیم اورژانس

آ.۱۱ داروهای دوره بستری در ICU (In-hospital ICU Medications)

- NITR_S: نیترات‌های مایع (Liquid Nitrates، داروهایی که رگ‌ها را گشاد می‌کنند و بار روی قلب را کاهش می‌دهند) در ICU
- NA_R_1_n، NA_R_2_n، NA_R_3_n: تعداد دفعات تجویز اوپیوئید در ICU (به ترتیب در روزهای اول، دوم و سوم بستری)
- NOT_NA_1_n، NOT_NA_2_n، NOT_NA_3_n: تعداد دفعات تجویز NSAID در ICU (به ترتیب در روزهای اول، دوم و سوم بستری)
- LID_S_n: لیدوکائین در ICU
- B_BLOK_S_n: بتابلوکر (Beta-blocker، داروهایی که ضربان قلب را کاهش می‌دهند و فشار را پایین می‌آورند) در ICU
- ANT_CA_S_n: مسدودکننده کانال کلسیم (Calcium Channel Blocker، کلاس دیگری از داروهای کنترل ضربان و فشار) در ICU
- GEPAR_S_n: هپارین (Heparin، داروی ضدانعقاد که از تشکیل لخته جدید جلوگیری می‌کند) در ICU
- ASP_S_n: آسپرین در ICU
- TIKL_S_n: Ticlid (تیکلوپیدین، داروی ضدپلاکت) در ICU

- Trental :TRENT_S_n (پنتوکسیفیلین، داروی بهبود جریان خون در مویرگ‌ها) در ICU

ب متغیرهای هدف به زبان ساده

در این پیوست هر یک از ۱۲ متغیر هدف دیتاست به زبان ساده و بدون اصطلاحات تخصصی توضیح داده شده است. سه پیامدی که در این پروژه اجباری‌اند با علامت ★ مشخص شده‌اند. برای انجام پروژه دانستن این توضیحات ضروری نیست، اما کمک می‌کند بفهمید مدل شما دقیقاً چه چیزی را پیش‌بینی می‌کند و چرا اشتباه در هر کدام هزینه متفاوتی دارد.

ب.۱ یک تصویر ساده از قلب

برای فهم این پیامدها کافی است قلب را این‌طور تصور کنید:

- **یک پمپ عضلانی چهارحفره‌ای:** دو حفره بالایی (*دهلیزها*) خون را جمع می‌کنند و دو حفره پایینی (*بطن‌ها*) آن را با فشار به ریه‌ها و کل بدن می‌فرستند. بطن‌ها پمپ اصلی‌اند.
- **یک سیستم برق داخلی:** یک «ضربان‌ساز طبیعی» در دهلیز راست، با نظم پالس الکتریکی می‌سازد. این پالس از دهلیزها عبور می‌کند، از یک «دروازه» به نام گره AV می‌گذرد و به بطن‌ها می‌رسد تا منقبض شوند. اختلال در این سیستم را *آریتمی* (بی‌نظمی ضربان) می‌گویند.
- **سکته قلبی:** یعنی رگی که به خود عضله قلب خون می‌رساند بسته شده و بخشی از عضله آسیب دیده یا مرده است. این بافت آسیب‌دیده هم پمپاژ را ضعیف می‌کند و هم می‌تواند سیستم برق را مختل کند. تقریباً همه عوارض زیر از همین دو مسیر ناشی می‌شوند.

ب.۲ عوارض مربوط به بی‌نظمی ضربان (آریتمی‌ها)

- ★ FIBR_PREDS **(فیبریلاسیون دهلیزی):** دهلیزها به جای انقباض منظم، سریع و نامنظم «می‌لرزند». مثل گروه کری که هر کس با ریتم خودش می‌خواند. معمولاً بلافاصله کشنده نیست، اما کارایی قلب را کم می‌کند، احتمال تشکیل لخته در دهلیز و در نتیجه سکته مغزی را بالا می‌برد و بیمار را به پایش و درمان بیشتر نیازمند می‌کند. این شایع‌ترین آریتمی پس از سکته قلبی است.

- PREDS_TAH **(تاکی‌کاردی فوق‌بطنی):** ضربان قلب ناگهان خیلی تند می‌شود و منشأ این تندی، بخش‌های بالای بطن‌ها (دهلیزها یا گره AV) است. معمولاً خطرش از آریتمی‌های بطنی کمتر است، ولی قلب آسیب‌دیده را خسته می‌کند. در این دیتاست بسیار نادر است.
- JELUD_TAH **(تاکی‌کاردی بطنی):** بطن‌ها، که پمپ اصلی‌اند، خودسرانه و خیلی تند می‌زنند. چون فرصت پر شدن ندارند، خون کمی پمپ می‌شود. این وضعیت خطرناک است و می‌تواند به فیبریلاسیون بطنی تبدیل شود.
- FIBR_JELUD **(فیبریلاسیون بطنی):** خطرناک‌ترین آریتمی. بطن‌ها به جای پمپ کردن فقط «می‌لرزند» و عملاً هیچ خونی به بدن نمی‌رسد. بدون شوک الکتریکی فوری (دستگاه دفیبریلاتور) در چند دقیقه به مرگ می‌انجامد. یکی از علل اصلی مرگ ناگهانی پس از سکته است.
- A_V_BLOK **(بلوک کامل دهلیزی‌بطنی):** «دروازه» گره AV کاملاً بسته می‌شود و پالس الکتریکی دهلیزها به بطن‌ها نمی‌رسد. بطن‌ها با ریتم پشتیبان بسیار کندی می‌زنند که برای بدن کافی نیست. معمولاً به ضربان‌ساز مصنوعی (pacemaker) نیاز پیدا می‌شود.

ب.۳ عوارض مربوط به ضعف پمپ

- OTEK_LANC **(ادم ریوی):** بطن چپ آسیب‌دیده نمی‌تواند خونی را که از ریه‌ها برمی‌گردد به‌خوبی پمپ کند. خون پشت ریه‌ها جمع می‌شود و مایع به داخل کیسه‌های هوایی نشت می‌کند؛ بیمار به معنای واقعی کلمه «در مایع غرق» می‌شود و به‌شدت تنگی نفس دارد. یک وضعیت اورژانسی است.
- ★ ZSN **(نارسایی مزمن قلب):** پمپ قلب به طور ماندگار ضعیف شده و دیگر نمی‌تواند به اندازه نیاز بدن خون برساند. برخلاف ادم ریوی که یک حمله حاد است، این یک وضعیت پایدار و طولانی‌مدت است: خستگی، تنگی نفس با فعالیت کم و تورم پاها. کیفیت زندگی و طول عمر بیمار را کاهش می‌دهد. شایع‌ترین پیامد این دیتاست است.

ب.۴ عوارض ساختاری و التهابی

- RAZRIV **(پارگی میوکارد):** دیواره عضله‌ای که در سکته مرده و نرم شده، زیر فشار پمپاژ پاره می‌شود؛ مثل لاستیکی که در نقطه ضعیفش می‌ترکد. تقریباً همیشه کشنده است، مگر جراحی فوری انجام شود. نادر است ولی بسیار مهم.

- DRESSLER **(سندرم درسلر):** چند هفته پس از سکته، سیستم ایمنی به اشتباه به بافت آسیب‌دیده قلب حمله می‌کند و پرده دور قلب (پریکارد) ملتهب می‌شود. علائمش درد قفسه سینه و تب است. معمولاً با داروهای ضدالتهاب درمان می‌شود و کمتر کشنده است.

ب.۵ عوارض مربوط به ادامه بیماری رگ‌ها

- REC_IM **(عود سکته قلبی):** در همان دوره بستری، دوباره یک رگ قلب بسته می‌شود و سکته جدیدی رخ می‌دهد. چون قلب از قبل آسیب دیده، سکته دوم معمولاً خطرناک‌تر است.
- P_IM_STEN **(آنژین پس از سکته):** بیمار دوباره درد قفسه سینه (آنژین) پیدا می‌کند، یعنی بخشی از عضله قلب هنوز خون کافی نمی‌گیرد. این یک «زنگ خطر» است که نشان می‌دهد ممکن است سکته دیگری در راه باشد.

ب.۶ پیامد نهایی: ★ LET_IS

این متغیر می‌گوید بیمار در طول بستری زنده ماند یا فوت کرد، و اگر فوت کرد علت اصلی چه بود. همان‌طور که در بخش ۱.۴ گفته شد، در این پروژه فقط «زنده» در برابر «فوت» را پیش‌بینی می‌کنید. علت‌های مرگ به زبان ساده:

- ۱. **شوک کاردیوژنیک:** قلب آن‌قدر ضعیف شده که فشار خون به‌شدت افت می‌کند و اندام‌ها خون کافی نمی‌گیرند.
- ۲. **ادم ریوی:** همان پر شدن ریه‌ها از مایع، در شکل شدید و کشنده.
- ۳. **پارگی میوکارد:** همان پارگی دیواره قلب.
- ۴. **نارسایی پیشرونده قلب:** پمپ قلب به تدریج و طی روزها از کار می‌افتد.
- ۵. **ترومبوآمبولی:** لخته خون کنده می‌شود و رگی حیاتی (مثلاً در ریه یا مغز) را می‌بندد.
- ۶. **آسیستول:** فعالیت الکتریکی قلب کاملاً متوقف می‌شود (همان «خط صاف» در نوار قلب).
- ۷. **فیبریلاسیون بطنی:** همان لرزش بطن‌ها که در بالا توضیح داده شد.

چرا این توضیحات برای شما مفید است؟ دانستن ماهیت هر پیامد به تفسیر نتایج کمک می‌کند. مثلاً عوارضی که با «ضعف پمپ» مرتبط‌اند (ZSN، OTEK_LANC، مرگ با علت ۱، ۲ و ۴) احتمالاً ویژگی‌های مشترکی دارند و همبستگی بین آن‌ها انتظار می‌رود؛ این همان چیزی است که مدل‌های چندبرچسبی **(امتیازی)** از آن استفاده می‌کنند. همچنین هزینه خطا یکسان نیست: از دست دادن یک بیمار در معرض فیبریلاسیون بطنی بسیار گران‌تر از یک هشدار اشتباه است، و این در انتخاب آستانه تصمیم اثر دارد.

تحویل‌دادنی‌ها

در پایان، موارد زیر را تحویل دهید:

- فایل CSV احتمال‌ها برای مجموعه آزمون خودتان (قالب بخش ۸).
- کد کامل و قابل اجرا (نوت‌بوک یا اسکریپت) با فایل نیازمندی‌ها.
- گزارش شامل:
  - روش تقسیم داده و پیش‌پردازش؛
  - جدول نتایج اعتبارسنجی متقابل برای سه مدل اجباری و سه پیامد (AUROC، AUPRC، Brier)؛
  - مدل نهایی و نتایج آن روی مجموعه آزمون، همراه با ماتریس درهم‌ریختگی در آستانه انتخابی؛
  - نمودار کالیبراسیون قبل و بعد از کالیبراسیون؛
  - نمودار SHAP برای پیش‌بینی مرگ؛
  - پاسخ به چهار سوال اجباری بخش سوالات و دو سوال مقاله‌ای که از بخش ۶ انتخاب کرده‌اید.

موارد امتیازی را در بخش جداگانه‌ای از گزارش با عنوان «بخش امتیازی» بیاورید.

مهلت تحویل

شما باید بخش های تحویل دادنی این پروژه را همراه با پاسخ سوالات تئوری (الزامی به وارد کردن پاسخ سوالات تئوری در قالب پایان نامه نیست و میتوانید به هر نحوی که راحت بودید آن را بنویسید) در قالب یک فایل زیپ تحویل بدهید.

مهلت تحویل پروژه: **۱۲ آبان، ساعت ۲۳:۵۹**

ارتباط با تدریس‌یاران

در صورت هر گونه ابهام در ارتباط با پروژه عملی می‌توانید با آیدی‌های زیر در ارتباط باشید:

- محدثه مقدم
- نیما صیاد

- ملیکا زارع
- صالح صباغ

همچنین در صورت وجود هر گونه ابهام در ارتباط با تمارین تئوری می‌توانید با آیدی‌های زیر در ارتباط باشید:

- ملیکا زارع
- روژان سعیدی‌کیا
- پرستو کهلایی
- آرش منوچهری
- امیرمحمد ذاکر